



アルファリズムと運動関連皮質電位を融合した運動イメージ脳波の非同期検出のためのハイブリッド法

劉曉林^a, 孫英^a, 王秀愛^b, 嚴俊^c, 江紫宇^d, 鄭德志^e.

^a 北京大学計測光電子工程学院、北京 100191、中国

^b School of Computer Science and Engineering, Beihang University, Beijing 100191, China

^c Intelligent Interconnection Technology Co., Ltd., Beijing 100086, China

中国通信大学アニメーション・デジタルアート学部、北京100024、中国

北京工業大学学際科学高等研究所、北京100081、中国

ARTICLE INFO

抄録

Keywords:

ブレインコンピュータ
インターフェース脳波運動
イメージ
非同期検出

ブレイン・コンピュータ・インターフェース(BCI)の開発により、脳信号のリアルタイム・モニタリングと変換による人間とコンピュータの直接的なインタラクションが可能になった。運動イメージ脳波(MI-EEG)システムは、非侵襲性と使いやすさで知られ、特に有望である。非同期システムは、柔軟性を高め、実用的なBCIアプリケーションの将来を示す。しかし、MI-EEGシステムにおける既存の非同期検出法は、満足いく精度と待ち時間を達成するには至っていない。本論文では、重み付きデンプスター・シェーファー理論(AMAD-DS)に基づき、アルファリズムの変化と運動関連皮質電位(MRCP)特徴を組み合わせたハイブリッド非同期検出法を提案する。AMADS法は、後頭部のアルファリズム特徴と感覚運動野のMRCP特徴の検出という、異なる領域の脳波信号を処理するために、ハイブリッドアーキテクチャと2つのマルチドメイン共同解析アルゴリズムを採用している。この方法は、重み付きD-S理論を用いて、これらの検出結果を決定レベルで融合し、最終出力を生成する。MI-EEGベースのBCIシステムで行われた実験では、AMAD-DSはMRCPまたはアルファリズム特徴のみを使用する方法を上回り、真陽性率を12.6%改善し、偽陽性率を0.5FPs/min減少させ、運動イメージの検出時間が500ms未満であることを保証した。オンライン実験により、本手法の有効性がさらに検証され、真陽性率91.1%、偽陽性率0.16FPs/minを達成した。

1. はじめに

近年、ブレイン・コンピュータ・インターフェース(BCI)は、人間とコンピュータのインタラクションのための新しいソリューションとして登場し、そのようなインタラクションの究極の形態となる準備が整っている。BCIは、リアルタイムの脳信号活動をモニターし、翻訳することで、人間とコンピュータの意図的なインタラクションを可能にする。特にヘルスケアにおいて、BCIは障害者にとって貴重なツールであることが証明されており、車椅子、義肢装具、ロボットなどの外部支援機器の制御を可能にしている[1, 2]。BCI技術の開発は、主に脳信号の収集と解析に使用できるセンサー技術と信号処理技術に依存している[3–10]。BCIシステムで利用される様々な信号収集モダリティの中で、脳波(EEG)測定は、その非侵入性、高い時間分解能、比較的低コストのため、広く好まれている。

脳波に基づくBCIパラダイムは、運動イメージ(MI)、P300誘発電位、定常視覚誘発電位(SSVEP)など、さまざまなタイプを包含している[11–14]。後者の2つのパラダイムは、脳のパターンを引き出すために外部刺激に依存するが、MIは、運動動作に関連するタスクを精神的にシミュレートすることで、ユーザーが自発的にコマンドを生成し、外部刺激の必要性を排除し、ユーザーフレンドリーにする一般的なアプローチである[15–19]。

MI-EEGベースのBCIシステムは、異なる制御モードに基づいて、同期と非同期の2つのカテゴリーに分類することができる[20, 21]。同期モードでは、ユーザーはあらかじめ設定された時間シーケンスに従ってMIタスクを実行しなければならない。多くの場合、タスクの開始時にコンピュータからプロンプト情報を受信する。ここでは、コンピュータが支配的な役割を担い、ユーザーは促されたとおりに受動的にタスクを完了するため、コンピュータとの厳密な同期が必要となる。逆に、非同期モードは、ユーザーがあらかじめ決められたタイミングやプロンプトなしに、自分の裁量でMIタスクを開始し、終了できるように、力を与えることを目的としている。

* コレスポンディング・オースー

E-mail address: zhengdezhi@bit.edu.cn (D. Zheng).

<https://doi.org/10.1016/j.measurement.2024.115167>

2024年6月25日オンライン版受理; 2024年6月17日改訂版受理; 2024年6月19日受理

Available online 25 June 2024

0263-2241/© 2024 Elsevier Ltd. テキストやデータマイニング、AIトレーニング、類似技術に関するものを含め、すべての権利が留保されている。



A hybrid method for asynchronous detection of motor imagery electroencephalogram fusing alpha rhythm and movement-related cortical potential

Xiaolin Liu^a, Ying Sun^a, Shuai Wang^b, Jun Yan^c, Ziyu Jiang^d, Dezhi Zheng^{e,*}

^a School of Instrumentation and Optoelectronic Engineering, Beihang University, Beijing 100191, China

^b School of Computer Science and Engineering, Beihang University, Beijing 100191, China

^c Intelligent Interconnection Technology Co., Ltd., Beijing 100086, China

^d School of Animation and Digital Arts, Communication University of China, Beijing 100024, China

^e Advanced Research Institute of Multidisciplinary Sciences, Beijing Institute of Technology, Beijing 100081, China

ARTICLE INFO

Keywords:

Brain computer interface
Electroencephalogram
Motor imagery
Asynchronous detection

ABSTRACT

The development of brain–computer interfaces (BCIs) enables direct human–computer interaction by real-time monitoring and translation of brain signals. Motor imagery electroencephalography (MI-EEG) systems, known for their non-invasiveness and user-friendliness, are particularly promising. Asynchronous systems, offering enhanced flexibility, represent the future of practical BCI applications. However, existing asynchronous detection methods in MI-EEG systems have yet to achieve satisfactory accuracy and latency. This paper proposes a hybrid asynchronous detection method that combines alpha rhythm changes and movement-related cortical potential (MRCP) features based on weighted Dempster–Shafer theory (AMAD-DS). The AMAD-DS method employs a hybrid architecture and two multi-domain joint analysis algorithms to process EEG signals from different areas: detecting alpha rhythm features in the occipital area and MRCP features in the sensorimotor area. The method fuses the results of these detections at the decision level using weighted D–S theory to produce the final output. Experiments conducted on a MI-EEG-based BCI system demonstrate that AMAD-DS outperformed methods using only MRCP or alpha rhythm features, improving the true positive rate by 12.6%, reducing the false positive rate by 0.5 FPs/min, and ensuring that the detection time of motor imagery onset is less than 500 ms. Online experiments further validate the method's effectiveness, achieving a true positive rate of 91.1% and a false positive rate of 0.16 FPs/min.

1. Introduction

In recent years, brain–computer interface (BCI) has emerged as a novel solution for human–computer interaction and is poised to become the ultimate form of such interaction. BCI enables intentional interaction between humans and computers by monitoring and translating real-time brain signal activity. Particularly in healthcare, BCI has proven to be a valuable tool for individuals with disabilities, granting them control over external assistive devices such as wheelchairs, prosthetics, and robots [1,2]. The development of BCI technology mainly relies on sensor technology and signal processing technology that can be used to collect and analyze brain signals [3–10]. Among the various signal acquisition modalities utilized in BCI systems, electroencephalogram (EEG) measurement is widely preferred due to its non-intrusiveness, high temporal resolution, and relatively low cost. EEG-based BCI paradigms encompass a range of types, including motor

imagery (MI), P300 evoked potentials, and steady-state visual evoked potentials (SSVEP) [11–14]. While the latter two paradigms depend on external stimuli to elicit brain patterns, MI is a popular approach where users generate commands voluntarily by mentally simulating motor movement-related tasks, eliminating the need for external stimuli and making it user-friendly [15–19].

MI-EEG-based BCI systems can be classified into two categories: synchronous and asynchronous, based on different control modes [20,21]. In the synchronous mode, users must perform MI tasks according to a preset time sequence, often receiving prompt information from the computer at the task's start. Here, the computer assumes the dominant role, and users passively complete tasks as prompted, requiring strict synchronization with the computer. Conversely, the asynchronous mode aims to empower users, allowing them to initiate and terminate MI tasks at their discretion, without predetermined timing and prompts.

* Corresponding author.

E-mail address: zhengdezhi@bit.edu.cn (D. Zheng).

<https://doi.org/10.1016/j.measurement.2024.115167>

Received 15 March 2024; Received in revised form 17 June 2024; Accepted 19 June 2024

Available online 25 June 2024

0263-2241/© 2024 Elsevier Ltd. All rights reserved, including those for text and data mining, AI training, and similar technologies.

ユーザがシステムを制御するためにMIタスクを実行する状態を制御状態と呼び、ユーザが制御のためにMIタスクに従事しない状態をアイドル状態と呼ぶ。同期モードと比較して、非同期モードはより柔軟性があり、ユーザの期待に近く、BCIシステムの実用化において避けられない傾向を示している。しかし、非同期モードの実装は著しく困難であり、より複雑な脳波信号解析法が要求される。同期モードでは、システムのタスクシーケンスはあらかじめ決まっており、ユーザが制御状態にある期間はよく定義されている。ここで、システムはMI-EEG分類法を適用して、制御状態からEEGデータをデコードし、ユーザが行っているMIタスクの種類を決定する。これに対して、非同期モードでは、システムは制御状態におけるユーザの期間を自律的に検出しなければならない。このように、非同期モードは分類法の他に、制御状態とアイドル状態を区別するために、特に調整されたMI-EEG非同期検出法を必要とする。

現在、BCIシステムでは同期モードが最も一般的な制御モードである。一般的に使用されているMI-EEG分類法と比較して、MI-EEG非同期検出法に関する研究は比較的少ない。以前の非同期検出研究では、特定のタイプのMIタスクは、通常、ユーザの状態遷移のための「スイッチ」として機能する。このアルゴリズムは、アイドル状態からコントロール状態への遷移の特徴として、このタスクによって誘発された脳波の感覚運動リズムの変化を検出する。この種の非同期検出法は満足のいく検出精度を達成できるが、ほとんどの研究は検出待ち時間について言及していないか、報告していない[22–24]。アイドル状態から制御状態への遷移には、しばしば数秒、あるいはそれ以上かかる[25]。もう一つの非同期検出法は、運動関連皮質電位(MRCP)を特徴量として利用し、ユーザのMIタスク実行意図を直接検出するものである。MRCPは通常、運動イメージの約1.5秒前に出現し、運動イメージの開始時に負のピークに達する[26]。MRCP特徴量とMIタスクの時間-位相関係により、MRCPベースの非同期検出法は数百ミリ秒以内に検出待ち時間を制御することができる[27–30]。しかし、MRCPは変動振幅が $5\sim 30\mu V$ で周波数範囲が 5Hz 以下であるため、脳波の背景雑音に溺死しやすい。MRCPの検出は単一試行の脳波信号では困難であり、この種の方法では検出精度が低くなる。さらに、MI-EEGベースのBCIシステムでは、開閉動作とそれに対応するEEG特徴量も非同期検出アルゴリズムを構築するために使用される。このタイプのアルゴリズムは、タスクパラダイムに追加アクションを導入する必要があるが、アルファリズムの変化のような明白で安定した特徴を誘発することができ、それによって高い検出精度を達成することができる。このタイプのアルゴリズムの欠点は、MIの意図ではなく、開閉動作を検出するため、MIオンセットの検出精度が低いことである。要約すると、既存のMI-EEG非同期検出法は、検出精度とレイテンシの実用的なレベルをまだ達成していない。

上記の課題を解決するために、本論文では開閉運動に助けられた非同期MIパラダイムを紹介する。このパラダイムにより、MI課題の前に脳波信号のアルファリズム変化とMRCPを同時に誘発することができる。ユーザの状態を識別するための基礎を形成することができる。このパラダイムに基づき、重み付きデンプスター・シェーファー理論(AMAD-DS)に基づき、アルファリズムの変化とMRCP特徴を組み合わせたハイブリッド非同期検出法を提案する。AMAD-DS法は、後頭部と感覚運動野からのマルチチャンネル脳波信号を並列に処理し、アルファリズムとMRCPの特徴を抽出するために2つのマルチドメイン共同解析法を構築する。これらの特徴量を用いて、ユーザの状態を個別に検出し、2つの検出結果の融合のための重み係数を提供することによって、各識別結果の信頼性を評価する。最後に、重み付きD-S理論に基づく提案ハイブリッド法は、2種類の特徴量の検出結果を組み合わせて、ユーザの状態の最終結果を得る。




図1. 開閉運動による非同期MIパラダイム。

提案手法を検証するために、MI-EEGに基づくBCI実験システムを開発し、複数の被験者を含むオフライン実験とオンライン実験の両方でテストした。オフライン実験の結果、AMAD-DS法はMRCP特徴のみを用いた場合と比較して、真陽性率(TPR)が平均12.6%増加し、偽陽性率(FPR)が平均0.5FPs/min減少し、検出精度が向上することが示された。さらに、アルファリズム特徴のみを用いた場合と比較して、AMAD-DS法は運動イメージの開始の検出精度を500ms以内に向上させた。オンライン実験では、AMAD-DS法はTPR 91.1%、FPR 0.16 FPs/minを達成した。

本論文の主な貢献は以下の通りである：

- 開閉動作に助けられた非同期MIパラダイムを提案し、ユーザの状態を特定するための基礎を形成する；
- 重み付きD-S理論に基づき、アルファリズムの変化とMRCP特徴を組み合わせたハイブリッドMI非同期検出法を提案する；
- 複数の被験者を含むオフラインおよびオンライン実験により、提案手法の検証を行うために、MI-EEGに基づくBCI実験システムを開発する。

本論文の残りの部分は以下のように構成されている。セクション 2 では提案する非同期検出法を説明し、セクション 3 では評価実験について説明し、セクション 4 では実験結果を示し、考察を行い、セクション 5 では我々の研究を結論付ける。

2. 方法

2.1. パラダイムとアルゴリズムの概要

本研究で導入した開閉運動による非同期MIパラダイムは、いくつかの理由から、(1)開閉運動は、誘導されたアルファリズム特徴とともに、MRCP特徴の検出精度の低さを補うことができる、(2)開閉運動は実行が簡単で、MIタスクと組み合わせてもユーザに過度の実行圧力を課さない、(3)神経筋経路機能障害の患者であっても、開閉運動を行う能力を保持することが多い、(4)アルファリズムとMRCPの特徴は大脳皮質の異なる領域から発生し、異なる周波数帯域を示し、相互作用が限定的であるため、誘導と検出が同時に容易になる、という理由からである。

図1に示すように、非同期MIパラダイムでは、MIタスクを開始する前に、ユーザが短時間の閉眼動作(約2秒)を行い、閉眼を伴うMIタスクの準備を行い、開眼直後にMIタスクを実行する。このパラダイムでは、閉眼運動によって誘発されるアルファリズムの変化と運動イメージによって誘発されるMRCPの両方が同時に起こる。これらの特徴は、MIタスクを実行するためにアイドル状態から制御状態へ遷移するユーザの意図に対応する。ユーザの目を閉じてから目を開けるまでの遷移は、アイドル状態からコントロール状態への遷移プロセスに対応し、遷移状態と呼ばれる。

The state where users perform MI tasks to control the system is termed the control state, while the state where users do not engage in MI tasks for control is termed the idle state. Compared to the synchronous mode, the asynchronous mode offers greater flexibility and aligns more closely with user's expectations, representing an inevitable trend in practical BCI system use. However, implementing the asynchronous mode is notably more challenging, demanding more complex EEG signal analysis methods. In the synchronous mode, the system's task sequence is predetermined, and the time period when the user is in the control state is well-defined. Here, the system applies the MI-EEG classification method to decode the EEG data from the control state, determining the type of MI task the user is performing. In contrast, in the asynchronous mode, the system must autonomously detect the user's periods in the control state, as they are not predefined. Thus, besides the classification method, the asynchronous mode requires a specifically tailored MI-EEG asynchronous detection method to differentiate between the control and idle states.

As of now, the synchronous mode remains the most common control mode in BCI systems. Compared to commonly used MI-EEG classification methods, there are relatively few studies on MI-EEG asynchronous detection methods in the literature. In earlier asynchronous detection research, a specific type of MI task typically serves as a "switch" for user state transition. The algorithms detect changes of sensorimotor rhythm in the EEG induced by this task as a feature of the transition from the idle state to the control state. While this type of asynchronous detection method can achieve satisfactory detection accuracy, most studies do not address or report the detection latency [22–24]. Transitioning from the idle state to the control state often takes several seconds or even longer [25]. Another type of asynchronous detection method utilizes movement-related cortical potential (MRCP) as a feature to directly detect the user's intention to perform MI tasks. MRCP typically appears approximately 1.5 s before motor imagery and reaches a negative peak at the onset of motor imagery [26]. Due to the time-phase relationship between MRCP features and MI tasks, the MRCP-based asynchronous detection method can control the detection latency within a few hundred milliseconds [27–30]. However, MRCP has a variation amplitude of 5–30 μV and a frequency range below 5 Hz, making it susceptible to drowning in the background noise of EEG. MRCP detection is challenging in single-trial EEG signals, leading to lower detection accuracy with this type of method. In addition, in the MI-EEG-based BCI systems, the eye opening and closing action and the corresponding EEG features are also used to construct asynchronous detection algorithms. Although this type of algorithm requires the introduction of additional actions in the task paradigm, it can induce obvious and stable features, such as alpha rhythm changes, thereby achieving a high detection accuracy. The shortcoming of this type of algorithm is that it detects eye opening and closing actions rather than MI intentions, so the detection accuracy of the MI onset is poor. In summary, existing MI-EEG asynchronous detection methods have not yet achieved a practical level of detection accuracy and latency.

To address the challenges described above, this paper introduces an asynchronous MI paradigm aided by eye opening and closing movements. This paradigm allows users to simultaneously induce alpha rhythm changes and MRCP in the EEG signal prior to the MI task, forming the basis for identifying the user's state. Based on this paradigm, the paper proposes a hybrid asynchronous detection method that combines alpha rhythm changes and MRCP features based on weighted Dempster–Shafer theory (AMAD-DS). The AMAD-DS method processes multi-channel EEG signals from the occipital and sensorimotor areas in parallel and constructs two multi-domain joint analysis methods to extract alpha rhythm and MRCP features. These features are used to detect the user's state individually, and the reliability of each discrimination result is evaluated based on the confusion matrix, which provides the weight coefficients for the fusion of the two detection results. Finally, the proposed hybrid method, based on the weighted D–S theory, combines the detection results of the two types of features




Fig. 1. Asynchronous MI paradigm aided by eye opening and closing movements.

to obtain the final result of the user's state. To validate the proposed method, a BCI experimental system based on MI-EEG is developed and tested through both offline and online experiments involving multiple subjects. The results of the offline experiment demonstrate that the AMAD-DS method, compared to using solely MRCP features, enhances the detection accuracy, with the true positive rate (TPR) increasing by an average of 12.6% and the false positive rate (FPR) decreasing by an average of 0.5 FPs/min. Furthermore, compared to using only alpha rhythm features, the AMAD-DS method improves the detection accuracy of the onset of motor imagery to within 500 ms. In the online experiments, the AMAD-DS method achieves a TPR of 91.1% and an FPR of 0.16 FPs/min.

The main contributions of this paper are listed as follows:

- Propose a asynchronous MI paradigm aided by eye opening and closing movements, forming the basis for identifying the user's state;
- Propose a hybrid MI asynchronous detection method that combines alpha rhythm changes and MRCP features based on weighted D–S theory;
- Develop a BCI experimental system based on MI-EEG for validation of the proposed method through offline and online experiments involving multiple subjects.

The rest of this paper is organized as follows: Section 2 explains the proposed asynchronous detection method; Section 3 describes the evaluation experiments; Section 4 presents the experimental results and provides the discussion; and Section 5 concludes our work.

2. Methods

2.1. Overview of paradigm and algorithm

The asynchronous MI paradigm aided by eye opening and closing movements is introduced in this study for several reasons: (1) Eye opening and closing movements, along with the induced alpha rhythm features, can compensate for the lack of detection accuracy of MRCP features; (2) Eye opening and closing movements are simple to execute and, when combined with MI tasks, do not impose excessive execution pressure on users; (3) Even patients with neuro-muscular pathway dysfunction often retain the ability to perform eye opening and closing movements; (4) Alpha rhythm and MRCP features originate from different areas of the cerebral cortex, exhibit distinct frequency band ranges, and have limited interaction, facilitating simultaneous induction and detection.

As shown in Fig. 1, the asynchronous MI paradigm involves users performing a brief eye-closing action (approximately 2 s) before initiating the MI task, preparing for the MI task with closed eyes, and performing the MI task immediately upon opening their eyes. In this paradigm, both the alpha rhythm changes induced by eye-closing movements and the MRCP induced by motor imagery occur simultaneously. These features correspond to the user's intention to transition from the idle state to the control state for performing MI tasks. The user's transition from closing his eyes to opening his eyes corresponds to the transition process from the idle state to the control state, referred to as the transition state.




図2. 提案するAMAD-DS法の概要。

提案するAMAD-DS法の枠組みを図2に示す。上述の非同期MIパラダイムに基づき、AMAD-DS法は、アルファリズム変化とMRCPを検出するために、様々な電極チャンネルからの脳波信号を同時に処理するハイブリッドアーキテクチャを採用している。その後、2つの検出結果を判定レベルで融合し、アイドル状態から制御状態へのユーザーの遷移意図を特定する。具体的には、アルファリズム検出アルゴリズムは、後頭部の脳波信号をフィルタリングして、5-15Hzの周波数帯域の信号成分を保持する。次に、共通空間パターン(CSP)法を用いて空間フィルタを構築し、マルチチャンネル情報を統合する。最後に、ヒルベルト-黄変換(HHT)を用いて、信号の限界スペクトルを特徴量として計算する。一方、MRCP検出アルゴリズムは、0.05~5Hzの周波数帯域の信号成分を保持したまま、感覚運動野の脳波信号を処理する。タスク関連成分分析(TRCA)法を用いて空間フィルタを構築し、多チャンネル情報を統合し、テンプレート相関分析により特徴量を得る。どちらの検出アルゴリズムも、特徴分類にサポートベクターマシン(SVM)を利用している。次に、2つの分類器によって出力された事後確率を、重み付きD-S理論に基づく決定レベルの融合に使用し、ユーザーの状態の最終的な識別結果を得る。この方法は、アイドル状態と制御状態を直接区別するのではなく、アイドル状態と遷移状態を区別することに留意すべきである。

提案するAMAD-DS法では、学習過程は分類問題に似ており、空間フィルタと分類器を学習するために、カテゴリラベルを持つ脳波データの複数回の試行を必要とする。ここで、ラベル $c = 0$ はアイドル状態、 $c = 1$ は遷移状態、 N_{ch} は電極チャンネル数、 N_{tp} は離散時点数を表す。実際のアルゴリズムの展開やテストでは、連続した脳波信号を処理するために、固定長のスライディングタイムウィンドウが使用される。時間窓は指定されたステップサイズに従って移動する。アルゴリズムは、各時間窓から遮断された信号を遷移状態またはアイドル状態に処理し、分類する。

また、 i 番目の時間窓で遮られた脳波データは、 $X_i^{(c)} \in \mathbb{R}^{N_{ch} \times N_{tp}}$ で表される。時間窓によって遮られるデータの長さは、一般に訓練セットの各試行のデータの長さと同じである。

2.2. アルファリズムの検出

人の目が開いているとき、または閉じているとき、脳波信号のアルファリズムの振幅(またはエネルギー)は大きく変化する。覚醒した閉眼状態では、脳波信号に高い振幅のアルファリズムが観察されるが、開眼状態では顕著な減衰が観察される。アルファリズムの主な周波数範囲は8~13Hzで、脳の後頭部に最も顕著な活動がある。アルファリズム検出アルゴリズムは、後頭部領域の電極チャンネルの脳波信号から特徴を抽出し、閉眼によって誘発されるアルファリズムの変化を検出することを目的としている。このアルゴリズムでは、まず5-15Hzの周波数帯域の後頭部の脳波信号にバンドパスフィルタリングを適用する。このバンド範囲は、個々の周波数帯域の潜在的な偏差を考慮するため、アルファリズムの範囲よりもわずかに広い。後頭部 $[]_T$ 領域のフィルタリングされた脳波信号を $X_{oc,i}^{(c)} = X_{i,j}^{(c)} \alpha$ と表し、 $i \in I_{oc-ch} \in \mathbb{R}^{N_{oc}-ch \times N_{tp}}$ と表し、 I_{oc-ch} は後頭部のチャンネルインデックスの集合を表し、 N_{oc-ch} チャンネルを含む。

多チャンネル脳波信号におけるアルファリズム特徴の統合を強化するために、アルファリズム検出アルゴリズムは、後頭部の脳波信号を空間的にフィルタリングするためにCSP法を採用している。CSP法は、空間フィルタを作成することで、2種類の脳波信号の分散差を最大化する[31]。空間フィルタ行列 W_{csp} は、固有値分解問題を解くことによって計算される:

$$\Sigma_0 W_{csp} = (\Sigma_0 + \Sigma_1) W_{csp} D_0, \quad (1)$$

ここで、 Σ_0 と Σ_1 はそれぞれアイドル状態と遷移状態の2種類の信号の平均共分散行列を表し、 D_0 は Σ_0 の固有値からなる対角行列を表す。このアルゴリズムは行列 W_{csp} の最初と最後の列のみを選択し、空間フィルタを構築する(W_{csp} と表記)。空間フィルタリングされた信号は $X_{oc,i}^{(c)} W_{csp}$ と表現でき、アルファリズム検出アルゴリズムはさらにHHTを利用して状態識別のための特徴を抽出する。HHTは非定常非線形脳波信号に適した解析方法である[32]。HHTの時間-周波数スペクトルの計算には、経験的モード分解とヒルベルトスペクトル解析の2つのステップがある[33, 34]。具体的には、検出アルゴリズムは、HHTの時間-周波数スペクトルに基づいて限界スペクトルを計算し、アルファリズム検出のための特徴ベクトルとして5-15Hzの周波数範囲に対応する部分を抽出し、 v_α と表記する。アルファリズム検出アルゴリズムは、非線形SVM分類器を用いて、特徴 v_α が遷移状態に属するか、アイドル状態に属するかを判定する。具体的には、シグモイド関数を用いて、分類器の出力 $f(v_\alpha)$ を0から1の間の確率値にマッピングし、分類器の事後確率を求める:

$$P(y_\alpha = 1 | v_\alpha) = \frac{1}{1 + \exp(a' f(v_\alpha) + b')}, \quad (2)$$

ここで、パラメータ a と b は(最大)尤度法で解くことができる。最後に、SVM分類器が出力する事後確率 $s_\alpha = P(y_\alpha = 1 | v_\alpha)$ をアルファリズム検出アルゴリズムの出力結果として使用し、ユーザーが遷移状態にある可能性を示す。

2.3. MRCP検出

MRCPの周波数範囲は5Hz以下であり、脳の感覚運動野で最も顕著な活動が見られる。MRCP検出アルゴリズムは、感覚運動野電極チャンネルの脳波信号から特徴を抽出し、




Fig. 2. Overview of the proposed AMAD-DS method.

The framework of the proposed AMAD-DS method is illustrated in Fig. 2. Based on the asynchronous MI paradigm described above, the AMAD-DS method employs a hybrid architecture to simultaneously process EEG signals from various electrode channels for detecting alpha rhythm changes and MRCP. Subsequently, the two detection results are fused at the decision level to identify the user's intention to transition from the idle state to the control state. Specifically, the alpha rhythm detection algorithm filters the EEG signal of the occipital area to retain signal components of the 5–15 Hz frequency band. It then constructs a spatial filter using the common spatial patterns (CSP) method to integrate multi-channel information. Finally, it uses the Hilbert–Huang transform (HHT) to calculate the signal's marginal spectrum as the features. On the other hand, the MRCP detection algorithm processes the EEG signal of the sensorimotor area, retaining signal components of the 0.05–5 Hz frequency band. It constructs a spatial filter using the task-related component analysis (TRCA) method to integrate multi-channel information and obtains features through template correlation analysis. Both detection algorithms utilize support vector machine (SVM) for feature classification. The posterior probabilities output by the two classifiers are then used for decision-level fusion based on the weighted D–S theory to obtain the final discrimination result of the user's state. It should be noted that this method does not directly distinguish between the idle state and the control state, but rather between the idle state and the transition state.

For the proposed AMAD-DS method, the training process resembles a classification problem, requiring multiple trials of EEG data with category labels to train the spatial filter and classifier. Let the EEG data of the i th trial be denoted as $X_i^{(c)} \in \mathbb{R}^{N_{ch} \times N_{tp}}$, where label $c = 0$ represents the idle state, $c = 1$ represents the transition state, N_{ch} represents the number of electrode channels, and N_{tp} represents the number of discrete time points. During the actual deployment or testing of the algorithm, a fixed-length sliding time window is used to process continuous EEG signals. The time window moves according to a specified step size. The algorithm processes and classifies the signal

intercepted of each time window to transition state or idle state. The EEG data intercepted by the i th time window is also represented by $X_i^{(c)} \in \mathbb{R}^{N_{ch} \times N_{tp}}$. The length of the data intercepted by the time window is generally the same as the data length of each trial in the training set.

2.2. Alpha rhythm detection

When a person's eyes are open or closed, the amplitude (or energy) of the alpha rhythm in the EEG signal undergoes significant changes. In the awake eyes-closed state, a higher amplitude alpha rhythm is observed in the EEG signal, while in the eyes-open state, there is a marked attenuation. The alpha rhythm's main frequency range is between 8–13 Hz, with the most pronounced activity in the occipital area of the brain. The alpha rhythm detection algorithm aims to extract features from the EEG signals of occipital area electrode channels to detect alpha rhythm changes induced by eye closure. The algorithm initially applies band-pass filtering to the EEG signal of the occipital area within the 5–15 Hz frequency band. This band range is slightly wider than the alpha rhythm range to account for potential deviations of individual frequency bands. The filtered EEG signal of occipital area is denoted as $X_{oc,i}^{(c)} = [x_{i,j}^{(c)} | j \in I_{oc-ch}]^T \in \mathbb{R}^{N_{oc-ch} \times N_{tp}}$, with I_{oc-ch} representing a set of channel indexes in occipital area, including N_{oc-ch} channels.

To enhance the integration of alpha rhythm features in multi-channel EEG signals, the alpha rhythm detection algorithm employs the CSP method to spatially filter the EEG signals of the occipital area. The CSP method maximizes the variance difference between two types of EEG signals by creating a spatial filter [31]. The spatial filter matrix W_{csp} is computed by solving the eigenvalue decomposition problem:

$$\Sigma_0 W_{csp} = (\Sigma_0 + \Sigma_1) W_{csp} D_0, \quad (1)$$

where Σ_0 and Σ_1 represent the average covariance matrices of the two types of signals, idle state and transition state, respectively, and D_0 represents the diagonal matrix composed of the eigenvalues of Σ_0 . The algorithm selects only the first and last columns of the matrix W_{csp} to construct a spatial filter, denoted as $\tilde{W}_{csp}$.

The spatial filtered signal can be expressed as $X_{oc,i}^T \tilde{W}_{csp}$, and the alpha rhythm detection algorithm further utilizes HHT to extract features for state discrimination. HHT is a suitable analysis method for non-stationary nonlinear EEG signals [32]. The calculation of the HHT time–frequency spectrum involves two steps: empirical mode decomposition and Hilbert spectrum analysis [33,34]. Specifically, the detection algorithm calculates the marginal spectrum based on the HHT time–frequency spectrum and extracts the part corresponding to the frequency range of 5–15 Hz as a feature vector for alpha rhythm detection, denoted as v_α .

The alpha rhythm detection algorithm uses a nonlinear SVM classifier to determine whether feature v_α belongs to the transition state or the idle state. Specifically, the sigmoid function is used to map the output $f(v_\alpha)$ of the classifier to a probability value between 0 and 1 to obtain the posterior probability of the classifier:

$$P(y_\alpha = 1 | v_\alpha) = \frac{1}{1 + \exp(a' f(v_\alpha) + b')}, \quad (2)$$

where parameters a' and b' can be solved by the maximum likelihood method. Finally, the posterior probability $s_\alpha = P(y_\alpha = 1 | v_\alpha)$ output by the SVM classifier will be used as the output result of the alpha rhythm detection algorithm, indicating the possibility of the user being in the transition state.

2.3. MRCP detection

The MRCP's frequency range is below 5 Hz, with the most pronounced activity in the sensorimotor area of the brain. The MRCP detection algorithm aims to extract features from the EEG signals of

ユーザの運動イメージ実行意図を検出することを目的としている。このアルゴリズムでは、まず0.05–5Hzの周波数帯域内の感覚運動野の脳波信号にバンドパスフィルタリングを適用する。感覚運動野 $[]_T$ のフィルタリングされたEEG信号を $X_{sm,i}^{(c)} = x_{i,j}^{(c)}$ と表し、 $i \in I_{sm-ch} \in R^{N_{sm-ch} \times N_{tr}}$ と表し、 I_{sm-ch} は N_{sm-ch} チャンネルを含む感覚運動野のチャンネルインデックスの集合を表す。

多チャンネル脳波信号におけるMRCP特徴の統合を強化するために、MRCP検出アルゴリズムは、感覚運動野の脳波信号を空間的にフィルタリングするためにTRCA法を採用している。TRCA法は、空間フィルタを構築し、その後、(c)タスク関連成分を抽出することで、タスク中の脳波信号の再現性を高める[35]。 $X_{sm,i}$ の各チャンネルの信号は、タスク関連信号sとタスク非関連信号nの2つのソース信号から構成されると見なすことができる。タスク関連信号sは複数の試行で一定であるが、タスク非関連信号nは変化する。この関係は、線形モデルを用いて次のように記述することができる：

$$x_{i,j}^{(c)} = a_{1,i,j}^{(c)} s + a_{2,i,j}^{(c)} n, \quad (3)$$

(c) (c) ここで、a と a は混合係数を表す。次に、全チャンネルの脳波信号の i, j 2, i, j 加重重を行い、次のようになる：

$$y_i^{(c)} = \sum_{j=1}^{N_{sm-ch}} w_j^{(c)} x_{i,j}^{(c)} = \sum_{j=1}^{N_{sm-ch}} \left(w_j^{(c)} a_{1,i,j}^{(c)} s + w_j^{(c)} a_{2,i,j}^{(c)} n \right). \quad (4)$$

TRCA法で解くべき問題は、 y_i からタスク(c)関連信号sを抽出することである。理想的な状況下でのこの問題の解は、 $y = s$ とすることであり、以下の条件を満たす必要がある：

$$\begin{cases} \sum_{j=1}^{N_{sm-ch}} w_j^{(c)} a_{1,i,j}^{(c)} = 1 \\ \sum_{j=1}^{N_{sm-ch}} w_j^{(c)} a_{2,i,j}^{(c)} = 0 \end{cases} \quad (5)$$

上記の問題は、試行間の共分散を最大化することで解くことができる。任意の2つの試行間の共分散は、以下のよう計算できる：

$$\text{Cov} \left[y_i^{(c)}, y_{i'}^{(c)} \right] = \sum_{j,j'=1}^{N_{sm-ch}} w_j^{(c)} w_{j'}^{(c)} \text{Cov} \left[x_{i,j}^{(c)}, x_{i',j'}^{(c)} \right]. \quad (6)$$

訓練セット(c)のカテゴリcに属するEEG試行回数を N_{tr} とすると、すべての試行組み合わせの共分散の和は以下のよう表すことができる：

$$\sum_{\substack{i,i'=1 \\ i \neq i'}}^{N_{tr}} \text{Cov} \left[y_i^{(c)}, y_{i'}^{(c)} \right] = \sum_{\substack{i,i'=1 \\ i \neq i'}}^{N_{tr}} \sum_{j,j'=1}^{N_{sm-ch}} w_j^{(c)} w_{j'}^{(c)} \text{Cov} \left[x_{i,j}^{(c)}, x_{i',j'}^{(c)} \right] = w^T S^{(c)} w. \quad (7)$$

有限解を得るためには、 y_i の分散に以下の正規化con(c)ストレイントを課す必要がある：

$$\text{Var} \left[y_i^{(c)} \right] = \sum_{i,i'=1}^{N_{tr}} \sum_{j,j'=1}^{N_{sm-ch}} w_j^{(c)} w_{j'}^{(c)} \text{Cov} \left[x_{i,j}^{(c)}, x_{i',j'}^{(c)} \right] = w^T Q^{(c)} w = 1. \quad (8)$$

最後に、上記の制約付き最適化問題は以下のよう解くことができる：

$$\hat{w} = \arg \max_w \frac{w^T S^{(c)} w}{w^T Q^{(c)} w}. \quad (9)$$

最適な空間フィルタリングベクトルは、行列 $Q^{-1} S$ の固有ベクトルを計算することによって導出され、対応する固有値は、タスク間の空間フィルタリングされた信号成分の一貫性を示す。このように、行列の固有値は降順に並べられ、3つの最大の固有値に対応する固有ベクトルが空間フィルタを構築するために選択される。

同時に、遷移状態とアイドル状態の2種類の脳波データからの空間フィルタをマージし、 $\hat{w}_{trc}$ とする。

空間フィルタはMRCP特徴抽出に重要である。また、本研究では、空間フィルタを構築するために、識別的正準パターンマッチング(DCPM)法を採用し、比較分析のベンチマークとする。DCPM法は、空間フィルタの構築を通じて、異なるタイプのEEG信号間の差を最大化し、類似したタイプのEEG信号間の差 $\{ \}$ を最小化する[36]。 $X_{\{sm\}}^{\{c\}}$ 、 $c = 0, 1$ の2つの信号テンプレートは、平均化することで得られる。

トレーニングセットにおけるマルチチャンネルEEG信号の複数回の試行、 $c = 0$ はアイドル状態、 $c = 1$ は遷移状態を表す。DCPM法では、脳波信号のクラス内差とクラス間差を定量化するために散布行列が採用され、以下のよう計算できる：

$$S_b = \left(\hat{X}_{sm}^{(0)} - \hat{X}_{sm}^{(1)} \right) \left(\hat{X}_{sm}^{(0)} - \hat{X}_{sm}^{(1)} \right)^T, \quad (10)$$

$$S_w = \sum_{c=0}^1 \sum_{i=1}^{N_{tr}^{(c)}} \left(X_{sm,i}^{(c)} - \hat{X}_{sm}^{(c)} \right) \left(X_{sm,i}^{(c)} - \hat{X}_{sm}^{(c)} \right)^T, \quad (11)$$

ここで、 $S_b \in R^{N_{sm-ch} \times N_{sm-ch}}$ はクラス間散布行列、 $N \times N^{(c)}$ $S_w \in R^{N_{sm-ch} \times N_{sm-ch}}$ はクラス内散布行列、 N_{tr} は訓練セットのカテゴリcに属する脳波試行数である。DCPM法の目的は、クラス間散布行列を最大化し、クラス内散布行列を最小化する最適な空間フィルタリングベクトルを見つけることである。この最適化問題は以下のよう解くことができる：

$$\hat{w} = \arg \max_w \frac{w^T S_b w}{w^T S_w w}. \quad (12)$$

最適な空間フィルタリングベクトルは、行列 $S_w^{-1} S_b$ の固有ベクトルを計算することによって得られる。行列 $S_w^{-1} S_b$ の固有値を降順に並べ、3つの最大の固有値と3つの最小の固有値に対応する固有ベクトルを選択して空間フィルタを構成する($\hat{w}_{dcpm}$ と表記)。TRCA法またはDCPM法によって構築された空間フィルタを一樣にWとする。空間的にフィルタリングされた信号は、それぞれ $X_{\{sm\}}^{\{c\}}$ W 、 $X_{\{sm\}}^{\{c\}} W$ 、 $X_{sm}^{(*)T} W$ と表される。このうち、 $X_{\{sm\}}^{\{c\}} W$ と $X_{\{sm\}}^{\{c\}} W$ は、それぞれアイドル状態と遷移状態に対応する信号テンプレートであり、マルチトライアル平均法により学習データを平均化することで得られる。 $X_{sm}^{(*)T} W$ は未知のカテゴリのテストデータを表す。3つの信号パターンの相関を分析するために、MRCP検出アルゴリズムは、一連の特徴を抽出するために、正準相関分析(CCA)法と2次元相関係数を利用する。これら2つの手法の計算過程をそれぞれcca [*]とcorr [*]とする。CCAアルゴリズムは、新しい射影行列AとBを構築することで、2つの行列間の潜在的な相関を最大化する[37]。MRCPの検出に使用される特徴量は、以下の処理によって計算される：

$$\rho_{11} = \text{corr} \left[\hat{X}_{sm}^{(0)T} W, X_{sm}^{(*)T} W \right], \quad (13)$$

$$\rho_{12} = \text{corr} \left[\hat{X}_{sm}^{(1)T} W, X_{sm}^{(*)T} W \right], \quad (14)$$

$$[A_1, B_1] = \text{cca} \left[\hat{X}_{sm}^{(0)T} W, X_{sm}^{(*)T} W \right], \quad (15)$$

$$[A_2, B_2] = \text{cca} \left[\hat{X}_{sm}^{(1)T} W, X_{sm}^{(*)T} W \right], \quad (16)$$

$$\rho_{21} = \text{corr} \left[\hat{X}_{sm}^{(0)T} W A_1, X_{sm}^{(*)T} W B_1 \right], \quad (17)$$

$$\rho_{22} = \text{corr} \left[\hat{X}_{sm}^{(1)T} W A_2, X_{sm}^{(*)T} W B_2 \right], \quad (18)$$

$$[A_3, B_3] = \text{cca} \left[\hat{X}_{sm}^{(0)T} W - \hat{X}_{sm}^{(1)T} W, X_{sm}^{(*)T} W - \hat{X}_{sm}^{(1)T} W \right], \quad (19)$$

sensorimotor area electrode channels to detect the user's intention to perform motor imagery. The algorithm initially applies band-pass filtering to the EEG signal of the sensorimotor area within the 0.05–5 Hz frequency band. The filtered EEG signal of sensorimotor area is denoted as $X_{\text{sm},i}^{(c)} = [x_{i,j}^{(c)} | j \in I_{\text{sm-ch}}]^T \in \mathbb{R}^{N_{\text{sm-ch}} \times N_{\text{tr}}}$, with $I_{\text{sm-ch}}$ representing a set of channel indexes in sensorimotor area, including $N_{\text{sm-ch}}$ channels.

To enhance the integration of MRCP features in multi-channel EEG signals, the MRCP detection algorithm employs the TRCA method to spatially filter the EEG signals of the sensorimotor area. The TRCA method enhances the reproducibility of the EEG signal during the task by constructing a spatial filter and subsequently extracting the task-related components [35]. Each channel's signal in $X_{\text{sm},i}^{(c)}$ can be viewed as comprising two source signals: the task-related signal s and the task-irrelevant signal n . The task-related signal s remains constant across multiple trials, whereas the task-irrelevant signal n varies. This relationship can be described using a linear model as follows:

$$x_{i,j}^{(c)} = a_{1,i,j}^{(c)} s + a_{2,i,j}^{(c)} n, \quad (3)$$

where $a_{1,i,j}^{(c)}$ and $a_{2,i,j}^{(c)}$ represent the mixing coefficients. Then perform a weighted sum of the EEG signals of all channels to get:

$$y_i^{(c)} = \sum_{j=1}^{N_{\text{sm-ch}}} w_j^{(c)} x_{i,j}^{(c)} = \sum_{j=1}^{N_{\text{sm-ch}}} \left(w_j^{(c)} a_{1,i,j}^{(c)} s + w_j^{(c)} a_{2,i,j}^{(c)} n \right). \quad (4)$$

The problem to be solved by the TRCA method is to extract the task-related signal s from $y_i^{(c)}$. The solution to this problem under ideal circumstances is to make $y = s$, and the following conditions need to be met:

$$\begin{cases} \sum_{j=1}^{N_{\text{sm-ch}}} w_j^{(c)} a_{1,i,j}^{(c)} = 1 \\ \sum_{j=1}^{N_{\text{sm-ch}}} w_j^{(c)} a_{2,i,j}^{(c)} = 0 \end{cases}. \quad (5)$$

The above problem can be solved by maximizing the covariance between trials. The covariance between any two trials can be calculated as follows:

$$\text{Cov} [y_i^{(c)}, y_{i'}^{(c)}] = \sum_{j,j'=1}^{N_{\text{sm-ch}}} w_j^{(c)} w_{j'}^{(c)} \text{Cov} [x_{i,j}^{(c)}, x_{i',j'}^{(c)}]. \quad (6)$$

If the number of EEG trials belonging to category c in the training set is $N_{\text{tr}}^{(c)}$, the sum of the covariances of all trial combinations can be expressed as follows:

$$\sum_{\substack{i,i'=1 \\ i \neq i'}}^{N_{\text{tr}}^{(c)}} \text{Cov} [y_i^{(c)}, y_{i'}^{(c)}] = \sum_{\substack{i,i'=1 \\ i \neq i'}}^{N_{\text{tr}}^{(c)}} \sum_{j,j'=1}^{N_{\text{sm-ch}}} w_j^{(c)} w_{j'}^{(c)} \text{Cov} [x_{i,j}^{(c)}, x_{i',j'}^{(c)}] = w^T S^{(c)} w. \quad (7)$$

In order to obtain a finite solution, the following normalization constraints need to be imposed on the variance of $y_i^{(c)}$:

$$\text{Var} [y_i^{(c)}] = \sum_{i,i'=1}^{N_{\text{tr}}^{(c)}} \sum_{j,j'=1}^{N_{\text{sm-ch}}} w_j^{(c)} w_{j'}^{(c)} \text{Cov} [x_{i,j}^{(c)}, x_{i',j'}^{(c)}] = w^T Q^{(c)} w = 1. \quad (8)$$

Finally, the above constrained optimization problem can be solved as follows:

$$\hat{w} = \arg \max_w \frac{w^T S^{(c)} w}{w^T Q^{(c)} w}. \quad (9)$$

The optimal spatial filtering vector is derived by computing the eigenvectors of the matrix $Q^{-1}S$, with the corresponding eigenvalues indicating the consistency of the spatially filtered signal components across tasks. Thus, the matrix's eigenvalues are arranged in descending order, and the eigenvectors corresponding to the three largest eigenvalues are chosen to construct a spatial filter. Simultaneously, the spatial filters

from the two types of EEG data in the transition state and the idle state are merged, denoted as $\bar{W}_{\text{trca}}$.

The spatial filter is crucial for MRCP feature extraction. This study also employs the discriminative canonical pattern matching (DCPM) method to construct a spatial filter, serving as a benchmark for comparative analysis. The DCPM method maximizes differences between different types of EEG signals through the construction of spatial filters, while minimizing differences between similar types of EEG signals [36]. Two signal templates, $\{\hat{X}_{\text{sm},c}^{(c)} | c = 0, 1\}$, can be obtained by averaging

multiple trials of the multi-channel EEG signals in the training set, with $c = 0$ representing the idle state and $c = 1$ representing the transition state. In the DCPM method, the scatter matrix is employed to quantify the intra-class and inter-class differences of EEG signals, which can be calculated as follows:

$$S_b = \left(\hat{X}_{\text{sm}}^{(0)} - \hat{X}_{\text{sm}}^{(1)} \right) \left(\hat{X}_{\text{sm}}^{(0)} - \hat{X}_{\text{sm}}^{(1)} \right)^T, \quad (10)$$

$$S_w = \sum_{c=0}^1 \sum_{i=1}^{N_{\text{tr}}^{(c)}} \left(X_{\text{sm},i}^{(c)} - \hat{X}_{\text{sm}}^{(c)} \right) \left(X_{\text{sm},i}^{(c)} - \hat{X}_{\text{sm}}^{(c)} \right)^T, \quad (11)$$

where $S_b \in \mathbb{R}^{N_{\text{sm-ch}} \times N_{\text{sm-ch}}}$ represents the inter-class scatter matrix, $S_w \in \mathbb{R}^{N_{\text{sm-ch}} \times N_{\text{sm-ch}}}$ represents the intra-class scatter matrix, and $N_{\text{tr}}^{(c)}$ is the number of EEG trials belonging to category c in the training set. The goal of the DCPM method is to find the optimal spatial filtering vector to maximize the inter-class scatter matrix and minimize the intra-class scatter matrix. This optimization problem can be solved as follows:

$$\hat{w} = \arg \max_w \frac{w^T S_b w}{w^T S_w w}. \quad (12)$$

The optimal spatial filtering vector can be obtained by calculating the eigenvectors of the matrix $S_w^{-1}S_b$. Arrange the eigenvalues of the matrix $S_w^{-1}S_b$ in descending order, and select the eigenvectors corresponding to the three largest eigenvalues and the three smallest eigenvalues to construct the spatial filter, denoted as $\bar{W}_{\text{dcpm}}$.

The spatial filters constructed by the TRCA method or DCPM method are uniformly denoted as W . The spatially filtered signals are represented as $\hat{X}_{\text{sm}}^{(0)T} W$, $\hat{X}_{\text{sm}}^{(1)T} W$, and $X_{\text{sm}}^{(*)T} W$ respectively. Among these, $\hat{X}_{\text{sm}}^{(0)T} W$ and $\hat{X}_{\text{sm}}^{(1)T} W$ are the signal templates corresponding to the idle state and the transition state respectively, obtained by averaging the training data through the multi-trial averaging method. $X_{\text{sm}}^{(*)T} W$ represents test data of unknown category. To analyze the correlation of signal patterns among the three, the MRCP detection algorithm utilizes the canonical correlation analysis (CCA) method and the two-dimensional correlation coefficient to extract a series of features. The calculation processes of these two methods are denoted by $\text{cca}[\cdot]$ and $\text{corr}[\cdot]$ respectively. The CCA algorithm maximizes the potential correlation between the two matrices by constructing new projection matrices A and B [37]. The features used for detecting MRCP are calculated through the following process:

$$\rho_{11} = \text{corr} \left[\hat{X}_{\text{sm}}^{(0)T} W, X_{\text{sm}}^{(*)T} W \right], \quad (13)$$

$$\rho_{12} = \text{corr} \left[\hat{X}_{\text{sm}}^{(1)T} W, X_{\text{sm}}^{(*)T} W \right], \quad (14)$$

$$[A_1, B_1] = \text{cca} \left[\hat{X}_{\text{sm}}^{(0)T} W, X_{\text{sm}}^{(*)T} W \right], \quad (15)$$

$$[A_2, B_2] = \text{cca} \left[\hat{X}_{\text{sm}}^{(1)T} W, X_{\text{sm}}^{(*)T} W \right], \quad (16)$$

$$\rho_{21} = \text{corr} \left[\hat{X}_{\text{sm}}^{(0)T} W A_1, X_{\text{sm}}^{(*)T} W B_1 \right], \quad (17)$$

$$\rho_{22} = \text{corr} \left[\hat{X}_{\text{sm}}^{(1)T} W A_2, X_{\text{sm}}^{(*)T} W B_2 \right], \quad (18)$$

$$[A_3, B_3] = \text{cca} \left[\hat{X}_{\text{sm}}^{(0)T} W - \hat{X}_{\text{sm}}^{(1)T} W, X_{\text{sm}}^{(*)T} W - \hat{X}_{\text{sm}}^{(1)T} W \right], \quad (19)$$

$$[A_4, B_4] = \text{cca} \left[\hat{X}_{\text{sm}}^{(1)\top} W - \hat{X}_{\text{sm}}^{(0)\top} W, X_{\text{sm}}^{(*)\top} W - \hat{X}_{\text{sm}}^{(0)\top} W \right], \quad (20)$$

$$\rho_{31} = \text{corr} \left[\left(\hat{X}_{\text{sm}}^{(0)\top} W - \hat{X}_{\text{sm}}^{(1)\top} W \right) A_3, \left(X_{\text{sm}}^{(*)\top} W - \hat{X}_{\text{sm}}^{(1)\top} W \right) B_3 \right], \quad (21)$$

$$\rho_{32} = \text{corr} \left[\left(\hat{X}_{\text{sm}}^{(1)\top} W - \hat{X}_{\text{sm}}^{(0)\top} W \right) A_4, \left(X_{\text{sm}}^{(*)\top} W - \hat{X}_{\text{sm}}^{(0)\top} W \right) B_4 \right], \quad (22)$$

ここで、 ρ_{11} と ρ_{12} は未知のクラス信号と2つのテンプレート間の直接相関を表し、 ρ_{21} と ρ_{22} は未知のクラス信号と2つのテンプレート間のCCAアルゴリズムによって得られた最大相関を表し、 ρ_{31} と ρ_{32} もCCAアルゴリズムによって得られた最大相関であるが、2種類の信号の違いを考慮する。これらの相関特徴を合わせてMRCP検出に用いる特徴ベクトル[特徴ベクトル]を $v_m = \rho_{11}, \rho_{12}, \rho_{21}, \rho_{22}, \rho_{31}, \rho_{32}$ とする。MRCP検出アルゴリズムはまた、特徴 v_m が(遷移)状態に属するか、アイドル状態に属するかをSVM分類器を用いて判定する。SVM分類器が出力する事後確率 $s_m = P(y_m = 1 | v_m)$ をMRCP検出アルゴリズムの出力結果として使用する。

2.4. 意思決定フュージョン

アルファリズム検出アルゴリズムとMRCP検出アルゴリズムは、それぞれ遷移状態とアイドル状態の識別結果を出力する。より良い意思決定融合効果を得るために、本研究では意思決定融合法に基づく重み付きD-S理論を設計する。この融合法の入力は、 α リズムとMRCP検出アルゴリズムによって得られた分類事後確率 s_α と s_m であり、出力は重み付きD-S理論によって得られた融合決定結果である。

D-S理論は、不確実な{情報}の知的処理とデータ融合のための標準的な手法である。[38]。非同期検出問題では、 $\Theta = \theta_0, \theta_1$ は全ての可能な決定の集合を表し、 θ_0 と θ_1 はそれぞれ{to {idle}}状態と遷移状態に対応し、 $2^\Theta = \phi, \theta_0, \theta_1, \theta_0, \theta_1$ は Θ のすべての可能な部分集合を表す。 2^Θ の特定の決定仮説に対して、アルファリズム検出アルゴリズムとMRCP検出アルゴリズムは2つの異なる証拠源を提供し、それらの(基本的な)確率割り当て() (BPA)関数はそれぞれ $m_{D-S,\alpha}(A_{D-S})$ と $m_{D-S,m}(A_{D-S})$ で表される。2つのBPA関数は単純に分類事後確率 s_α と s_m に設定できるが、2つの検出アルゴリズムは一般に遷移状態とアイドル状態の識別において様々な精度を示す。分類器の決定の信頼性を考慮することなく、2つの分類器の出力を直接融合すると、実際の結果から逸脱する可能性がある。異なる分類器に重みを設定することで、決定融合の全体的な性能を向上させることができる。分類器の信頼性は、決定融合における重み係数として、混同行列に基づいて評価される。アルファリズム検出アルゴリズムを例にとると、そのSVM分類器の混同行列は次のように表すことができる：

$$M_{c,\alpha} = \begin{bmatrix} c_{00} & c_{01} \\ c_{10} & c_{11} \end{bmatrix}, \quad (23)$$

ここで、 c_{00} はアイドル状態が正しく判定された試行数、 c_{11} は遷移状態が正しく判定された試行数、 c_{01} はアイドル状態が遷移状態と判定された試行数、 c_{10} は遷移状態がアイドル状態と判定された試行数を表す。分類器のグローバルな信頼性は、精度によって測定することができ、それは以下のように計算することができる：

$$\bar{\gamma}_\alpha = \frac{c_{00} + c_{11}}{c_{00} + c_{01} + c_{10} + c_{11}}. \quad (24)$$

アイドル状態と遷移状態に対する分類器の局所的な信頼性は、以下のように計算される。

$$\gamma_{\alpha,0} = \frac{c_{00}}{c_{00} + c_{01}}, \quad (25)$$

$$\gamma_{\alpha,1} = \frac{c_{11}}{c_{10} + c_{11}}. \quad (26)$$

局所的な信頼性を分類器の事後確率 s_α に統合し、正規化することで得られる：

$$s'_\alpha = \frac{\gamma_{\alpha,1} \times s_\alpha}{\gamma_{\alpha,0} \times \bar{s}_\alpha + \gamma_{\alpha,1} \times s_\alpha}, \quad (27)$$

ここで、 s_α は遷移状態に対応する確率、 $\bar{s}_\alpha = 1 - s_\alpha$ はアイドル状態に対応する確率である。これに基づき、アルファリズム検出アルゴリズムのBPA関数は以下のように定義される：

$$m_{D-S,\alpha}(\emptyset, \theta_0, \theta_1, \{\theta_0, \theta_1\}) = (0, \bar{\gamma}_\alpha(1 - s'_\alpha), \bar{\gamma}_\alpha s'_\alpha, 1 - \bar{\gamma}_\alpha). \quad (28)$$

上記の処理により、MRCP検出アルゴリズムのBPA関数も以下のように定義できる：

$$m_{D-S,m}(\emptyset, \theta_0, \theta_1, \{\theta_0, \theta_1\}) = (0, \bar{\gamma}_m(1 - s'_m), \bar{\gamma}_m s'_m, 1 - \bar{\gamma}_m). \quad (29)$$

最後に、2つの検出アルゴリズムのBPA関数をD-S理論を通して融合し、最終的な決定結果を得る：

$$\begin{aligned} m_{D-S,\text{total}}(A_{D-S}) &= m_{D-S,\alpha}(A_{D-S}) \oplus m_{D-S,m}(A_{D-S}) \\ &= \frac{1}{1 - K_{D-S}} \sum_{B_{D-S} \cap C_{D-S} = A_{D-S}} m_{D-S,\alpha}(B_{D-S}) m_{D-S,m}(C_{D-S}), \end{aligned} \quad (30)$$

ここで、 $K_{D-S} = \phi_{BD-S \cap CD-S = \emptyset} m_{D-S,\alpha}(B_{D-S}) m_{D-S,m}(C_{D-S})$ は $m_{D-S,\alpha}$ と $m_{D-S,m}$ の矛盾の度合いである。

提案する重み付きD-S決定融合法の有効性を検証するために、本研究では、比較分析のベンチマークとして、単純決定融合法と確率的融合法と呼ばれる他の2つの決定融合法も設計した。 T_α と T_m を用いて、それぞれある脳波トレイルに対するアルファリズム検出アルゴリズムとMRCP検出アルゴリズムの決定結果を表す。単純決定融合法の決定結果は、次のように表すことができる：

$$T = \begin{cases} T_m, & \text{if } (T_\alpha = 1) \\ 0, & \text{if } (T_\alpha = 0) \end{cases}, \quad (31)$$

ここで、 $T_\alpha = 0$ と $T_\alpha = 1$ はそれぞれ、 α リズム検出アルゴリズムの決定結果がアイドル状態と遷移状態であることを示し、 $T_m = 0$ と $T_m = 1$ はそれぞれ、MRCP検出アルゴリズムの決定結果がアイドル状態と遷移状態であることを示す。確率的融合法の決定結果は、次のように表すことができる：

$$T = \begin{cases} 0, & \text{if } (T_{\alpha,\text{new}} = 0 \text{ and } T_{m,\text{new}} = 0) \\ 0, & \text{if } (T_{\alpha,\text{new}} = 0 \text{ and } T_{m,\text{new}} = 1 \text{ and } \bar{s}_{\alpha,\text{new}} \geq s_{m,\text{new}}) \\ 1, & \text{if } (T_{\alpha,\text{new}} = 0 \text{ and } T_{m,\text{new}} = 1 \text{ and } \bar{s}_{\alpha,\text{new}} < s_{m,\text{new}}) \\ 1, & \text{if } (T_{\alpha,\text{new}} = 1 \text{ and } T_{m,\text{new}} = 0 \text{ and } s_{\alpha,\text{new}} \geq \bar{s}_{m,\text{new}}) \\ 0, & \text{if } (T_{\alpha,\text{new}} = 1 \text{ and } T_{m,\text{new}} = 0 \text{ and } s_{\alpha,\text{new}} < \bar{s}_{m,\text{new}}) \\ 1, & \text{if } (T_{\alpha,\text{new}} = 1 \text{ and } T_{m,\text{new}} = 1) \end{cases}, \quad (32)$$

ここで、 s_α と $\bar{s}_\alpha = 1 - s_\alpha$ はそれぞれ α リズム検出アルゴリズムで与えられた遷移状態とアイドル状態の確率であり、 s_m と $\bar{s}_m = 1 - s_m$ はそれぞれMRCP検出アルゴリズムで与えられた遷移状態とアイドル状態の確率である。

3. 評価結果

3.1. 実験システム

提案するAMAD-DS法を評価するために、MI-EEGベースのBCI実験システムを設計・実装した：図3に示すように、

$$[A_4, B_4] = \text{cca} \left[\hat{X}_{\text{sm}}^{(1)\top} W - \hat{X}_{\text{sm}}^{(0)\top} W, X_{\text{sm}}^{(*)\top} W - \hat{X}_{\text{sm}}^{(0)\top} W \right], \quad (20)$$

$$\rho_{31} = \text{corr} \left[\left(\hat{X}_{\text{sm}}^{(0)\top} W - \hat{X}_{\text{sm}}^{(1)\top} W \right) A_3, \left(X_{\text{sm}}^{(*)\top} W - \hat{X}_{\text{sm}}^{(1)\top} W \right) B_3 \right], \quad (21)$$

$$\rho_{32} = \text{corr} \left[\left(\hat{X}_{\text{sm}}^{(1)\top} W - \hat{X}_{\text{sm}}^{(0)\top} W \right) A_4, \left(X_{\text{sm}}^{(*)\top} W - \hat{X}_{\text{sm}}^{(0)\top} W \right) B_4 \right], \quad (22)$$

where ρ_{11} and ρ_{12} represent the direct correlation between the unknown class signal and the two templates; ρ_{21} and ρ_{22} represent the maximum correlation obtained through the CCA algorithm between the unknown class signal and the two templates; ρ_{31} and ρ_{32} are also the maximum correlation obtained by the CCA algorithm but take into account the difference between the two types of signals. These correlation features together form the feature vector used for MRCP detection, denoted as $v_m = [\rho_{11}, \rho_{12}, \rho_{21}, \rho_{22}, \rho_{31}, \rho_{32}]$.

The MRCP detection algorithm also uses the SVM classifier to determine whether the feature v_m belongs to the transition state or the idle state. The posterior probability $s_m = P(y_m = 1 | v_m)$ output by the SVM classifier will be used as the output result of the detection algorithm.

2.4. Decision fusion

The alpha rhythm detection algorithm and the MRCP detection algorithm output the discrimination results for the transition state and the idle state, respectively. To achieve a better decision fusion effect, this study designs a decision fusion method based weighted D-S theory. The input of this fusion method is the classification posterior probabilities s_α and s_m obtained through the alpha rhythm and MRCP detection algorithms, and the output is the fusion decision result obtained through the weighted D-S theory.

D-S theory is a standard method for intelligent processing and data fusion of uncertain information [38]. In the asynchronous detection problem, $\Theta = \{\theta_0, \theta_1\}$ represents the set of all possible decisions, where θ_0 and θ_1 correspond to the idle state and the transition state, respectively, and $2^\Theta = \{\emptyset, \theta_0, \theta_1, \{\theta_0, \theta_1\}\}$ represents all possible subsets of Θ . For a particular decision hypothesis in 2^Θ , the alpha rhythm detection algorithm and the MRCP detection algorithm provide two distinct sources of evidence, with their basic probability assignment (BPA) functions represented by $m_{D-S,\alpha}(A_{D-S})$ and $m_{D-S,m}(A_{D-S})$, respectively. While the two BPA functions can be simply set to the classification posterior probabilities s_α and s_m , the two detection algorithms generally exhibit varying accuracy in identifying transition states and idle states. Directly fusing the outputs of the two classifiers without considering the credibility of the classifier's decision may lead to deviations from the actual result. Setting weights for different classifiers can enhance the overall performance of decision fusion. The credibility of the classifier is evaluated based on the confusion matrix as the weight coefficients in decision fusion.

Taking the alpha rhythm detection algorithm as an example, the confusion matrix of its SVM classifier can be expressed as:

$$M_{c,\alpha} = \begin{bmatrix} c_{00} & c_{01} \\ c_{10} & c_{11} \end{bmatrix}, \quad (23)$$

where c_{00} represents the number of trials in which the idle state is correctly judged, c_{11} represents the number of trials in which the transition state is correctly judged, c_{01} represents the number of trials in which the idle state is judged as the transition state, and c_{10} represents the number of trials in which the transition state is judged as the idle state. The global credibility of the classifier can be measured by accuracy, which can be calculated as follows:

$$\bar{\gamma}_\alpha = \frac{c_{00} + c_{11}}{c_{00} + c_{01} + c_{10} + c_{11}}. \quad (24)$$

The local credibility of the classifier for the idle state and the transition state is calculated as follows:

$$\gamma_{\alpha,0} = \frac{c_{00}}{c_{00} + c_{01}}, \quad (25)$$

$$\gamma_{\alpha,1} = \frac{c_{11}}{c_{10} + c_{11}}. \quad (26)$$

Integrating the local credibility into the posterior probability s_α of the classifier and normalizing it can obtain:

$$s'_\alpha = \frac{\gamma_{\alpha,1} \times s_\alpha}{\gamma_{\alpha,0} \times \bar{s}_\alpha + \gamma_{\alpha,1} \times s_\alpha}, \quad (27)$$

where s_α is the probability corresponding to the transition state, and $\bar{s}_\alpha = 1 - s_\alpha$ is the probability corresponding to the idle state. On this basis, the BPA function of the alpha rhythm detection algorithm is defined as follows:

$$m_{D-S,\alpha}(\emptyset, \theta_0, \theta_1, \{\theta_0, \theta_1\}) = (0, \bar{\gamma}_\alpha (1 - s'_\alpha), \bar{\gamma}_\alpha s'_\alpha, 1 - \bar{\gamma}_\alpha). \quad (28)$$

According to the above process, the BPA function of the MRCP detection algorithm can also be defined as:

$$m_{D-S,m}(\emptyset, \theta_0, \theta_1, \{\theta_0, \theta_1\}) = (0, \bar{\gamma}_m (1 - s'_m), \bar{\gamma}_m s'_m, 1 - \bar{\gamma}_m). \quad (29)$$

Finally, the BPA functions of the two detection algorithms are fused through the D-S theory to obtain the final decision result:

$$\begin{aligned} m_{D-S,\text{total}}(A_{D-S}) &= m_{D-S,\alpha}(A_{D-S}) \oplus m_{D-S,m}(A_{D-S}) \\ &= \frac{1}{1 - K_{D-S}} \sum_{B_{D-S} \cap C_{D-S} \cap A_{D-S}} m_{D-S,\alpha}(B_{D-S}) m_{D-S,m}(C_{D-S}), \end{aligned} \quad (30)$$

where $K_{D-S} = \sum_{B_{D-S} \cap C_{D-S} = \emptyset} m_{D-S,\alpha}(B_{D-S}) m_{D-S,m}(C_{D-S})$ is the degree of contradiction between $m_{D-S,\alpha}$ and $m_{D-S,m}$.

In order to verify the effectiveness of the proposed weighted D-S decision fusion method, this study also designed two other decision fusion methods as the benchmark for comparative analysis, respectively called the simple decision fusion method and the probabilistic fusion method. Use T_α and T_m to represent the decision results of the alpha rhythm detection algorithm and the MRCP detection algorithm for a certain EEG trail respectively. The decision result of the simple decision fusion method can be expressed as:

$$T = \begin{cases} T_m, & \text{if } (T_\alpha = 1) \\ 0, & \text{if } (T_\alpha = 0) \end{cases}, \quad (31)$$

where $T_\alpha = 0$ and $T_\alpha = 1$ respectively indicate that the decision result of the alpha rhythm detection algorithm is the idle state and the transition state, and $T_m = 0$ and $T_m = 1$ respectively indicate that the decision result of the MRCP detection algorithm is the idle state and the transition state. The decision result of the probabilistic fusion method can be expressed as:

$$T = \begin{cases} 0, & \text{if } (T_{\alpha,\text{new}} = 0 \text{ and } T_{m,\text{new}} = 0) \\ 0, & \text{if } (T_{\alpha,\text{new}} = 0 \text{ and } T_{m,\text{new}} = 1 \text{ and } \bar{s}_{\alpha,\text{new}} \geq s_{m,\text{new}}) \\ 1, & \text{if } (T_{\alpha,\text{new}} = 0 \text{ and } T_{m,\text{new}} = 1 \text{ and } \bar{s}_{\alpha,\text{new}} < s_{m,\text{new}}) \\ 1, & \text{if } (T_{\alpha,\text{new}} = 1 \text{ and } T_{m,\text{new}} = 0 \text{ and } s_{\alpha,\text{new}} \geq \bar{s}_{m,\text{new}}) \\ 0, & \text{if } (T_{\alpha,\text{new}} = 1 \text{ and } T_{m,\text{new}} = 0 \text{ and } s_{\alpha,\text{new}} < \bar{s}_{m,\text{new}}) \\ 1, & \text{if } (T_{\alpha,\text{new}} = 1 \text{ and } T_{m,\text{new}} = 1) \end{cases}, \quad (32)$$

where s_α and $\bar{s}_\alpha = 1 - s_\alpha$ are respectively the probabilities of the transition state and the idle state given by the alpha rhythm detection algorithm, and s_m and $\bar{s}_m = 1 - s_m$ are respectively the probabilities of the transition state and the idle state given by the MRCP detection algorithm.

3. Evaluation

3.1. Experiment system

To evaluate the proposed AMAD-DS method, an MI-EEG-based BCI experimental system is designed and implemented, comprising four




図3. 実験システムのフレームワーク




図4. オフライン実験における脳波データの各試行のタスクタイミング。

EEG収集、データデコーディング、信号処理、タスクインターフェースの4つのモジュールから構成される。EEG収集モジュールは、DSI-24ドライ電極無線装置を採用し、被験者からマルチチャンネルEEG信号を収集し、アナログ-デジタル変換を行う。この装置は、ドライ電極を収集することで、頭皮の前処理と導電性ペーストの必要性をなくし、システムをより汎用性の高い、様々なシナリオでの展開をより迅速に行うことができる。取得には、PzとFPzがそれぞれ基準電極と地上電極として機能し、残りの電極は測定電極として機能する。サンプリング周波数は300Hzに設定されている。データデコーディングモジュールは、収集装置のデータ形式を解釈し、分析に必要なマルチチャンネル脳波データを選択し、システムによる後続の処理のために、指定されたエンコーディング形式を持つデータフレームに再編成する。システムの重要な構成要素である信号処理モジュールは、オンライン操作中に非同期検出アルゴリズムをリアルタイムで実行したり、脳波データをオフラインモードで保存したりする役割を担っている。このモジュールはPythonでプログラムされ、リアルタイム処理を保証するためにマルチスレッド協調フレームワークを採用している。具体的には、データ転送スレッドはデータ復号モジュールからリアルタイムの脳波データを取得し、必要に応じて他のスレッドに転送する。非同期検出スレッドは非同期検出アルゴリズムを実行し、被験者の制御状態とアイドル状態を区別するためにリアルタイムの脳波信号を分析する。タスクインターフェースモジュールは、インタラクティブなインターフェースを使用して、被験者をタスクに誘導し、システムの分析結果を表示する。

3.2. オフライン実験

模擬オンライン非同期検出実験は、6人の被験者のオフライン脳波データを用いて実施した。これらのデータは、本研究でデザインされた開閉運動によって支援される非同期MIパラダイムを用いて収集されたものである。各被験者は4回のセッションでMIタスクを実行し、合計120回の試行を行う。の間の休息時間

ルゴリズムをテストする。セッション(約5~10分)を被験者が決定する。各セッションにおいて、被験者は手と足の動きの想像を含む30回の連続したMI課題の試行を行う。各タイプのMIタスクは15回実行され、出現順序は疑似ランダム化される。各試行は、図4に示す課題のタイミングに従って12秒間続く。各試行の開始時に、''Close Eyes''が3秒間画面に表示され、その間、被験者はタスクの準備をするために目を閉じる。その後、短いビーブ音が鳴らされ、その後、MIタスクカテゴリを表す絵のプロンプトが6秒間表示される。その後、被験者はビーブ音の直後に目を開け、絵のプロンプトに従って対応する運動イメージを行う。スクリーンに''休息''が現れると、被験者は運動イメージを停止し、3秒間の休息をとった。

前述のオフライン脳波データを用いて、提案するAMAD-DSアルゴリズムと他のいくつかのベンチマークア

- AAD: このアルゴリズムは、本研究で提案されたアルファリズム検出アルゴリズムのみに依存している；
- MAD: このアルゴリズムは、TRCA空間フィルタを利用した、本研究で提案されたMRCP検出アルゴリズムのみに依存している；
- MAD*: このアルゴリズムは、DCPM空間フィルタを利用した、本研究で提案されたMRCP検出アルゴリズムのみに依存している；
- AMAD-D: このアルゴリズムは、単純な決定融合法を採用し、意思決定のためにアルファリズム検出アルゴリズムとMRCP検出アルゴリズムの結果を組み合わせる；
- AMAD-P: 確率的融合法を採用し、アルファリズム検出アルゴリズムとMRCP検出アルゴリズムの結果を組み合わせる意思決定を行うアルゴリズム；
- AMAD-D: このアルゴリズムは、重み付きD-S理論に基づく決定融合法を採用し、意思決定のためにアルファリズム検出アルゴリズムとMRCP検出アルゴリズムの結果を組み合わせる。

オフライン実験では、各被験者の最初のセッションの脳波データをアルゴリズムのトレーニングに使用し、残りの3つのセッションの脳波データをアルゴリズムのテストに使用する。遷移状態とアイドル状態の脳波データから学習データを抽出する方法を図4に示す。テスト中のオンライン非同期検出をより正確にシミュレートするために、各セッションで連続した脳波信号を処理するために2秒のスライディング時間窓が使用される。時間窓は0.1秒単位で移動する。非同期検出アルゴリズムは、各時間ウィンドウで傍受された信号を遷移状態またはアイドル状態に処理し、分類する。アルゴリズムが遷移状態として連続する3つの時間窓を検出するとき、被験者はアイドル状態から制御状態へ遷移することを意図していると推論する。




Fig. 3. Framework of experiment system.




Fig. 4. Task timing of each trial of EEG data in the offline experiment.

modules: EEG acquisition, data decoding, signal processing, and task interface, as depicted in Fig. 3. The EEG acquisition module employs the DSI-24 dry electrode wireless equipment to collect multi-channel EEG signals from the subjects and perform analog-to-digital conversion. This equipment, with its dry electrode collection, eliminates the need for scalp pretreatment and conductive paste, making the system more versatile and quicker to deploy in various scenarios. For acquisition, Pz and FPz serve as reference and ground electrodes respectively, while the remaining electrodes function as measurement electrodes. The sampling frequency is set to 300 Hz. The data decoding module deciphers the data format of the acquisition equipment, selects the necessary multi-channel EEG data for analysis, and reorganizes it into a data frame with a specified encoding format for subsequent processing by the system. The signal processing module, a key component of the system, is responsible for executing the asynchronous detection algorithms in real-time during online operation or for storing EEG data in offline mode. This module is programmed in Python and employs a multi-threaded collaborative framework to ensure real-time processing. Specifically, the data forwarding thread acquires real-time EEG data from the data decoding module and forwards it to other threads as needed. The asynchronous detection thread executes the asynchronous detection algorithm, analyzing real-time EEG signals to distinguish between the subject's control and idle states. The task interface module guides subjects through tasks using an interactive interface and displays the system's analysis results.

3.2. Offline experiment

The simulated online asynchronous detection experiment is conducted using offline EEG data from 6 subjects. These data are collected using the asynchronous MI paradigm assisted by eye opening and closing movements designed in this study. Each subject performs MI tasks over four sessions, totaling 120 trials. The rest time between

sessions, approximately 5 to 10 min, is determined by the subject. In each session, subjects perform 30 consecutive trials of the MI task, involving imagination of hand and foot movements. Each type of MI task is performed 15 times, with the order of appearance pseudo-randomized. Each trial lasts 12 s, following the task timing shown in Fig. 4. At the start of each trial, "Close Eyes" is displayed on the screen for 3 s, during which subjects close their eyes to prepare for the task. Subsequently, a short beep sounds, followed by a 6-s display of a picture prompt representing the MI task category. Subjects then open their eyes immediately after the beep and perform the corresponding motor imagery according to the picture prompt. When "Rest" appears on the screen, subjects cease motor imagery and had a 3-s rest period.

Using the aforementioned offline EEG data, this study tests the proposed AMAD-DS algorithm and several other benchmark algorithms.

- AAD: the algorithm relies solely on the alpha rhythm detection algorithm proposed in this study;
- MAD: the algorithm relies solely on the MRCP detection algorithm proposed in this study, utilizing the TRCA spatial filter;
- MAD*: the algorithm relies solely on the MRCP detection algorithm proposed in this study, utilizing the DCPM spatial filter;
- AMAD-D: the algorithm combines the results of the alpha rhythm detection algorithm and the MRCP detection algorithm for decision-making, employing the simple decision fusion method;
- AMAD-P: the algorithm combines the results of the alpha rhythm detection algorithm and the MRCP detection algorithm for decision-making, employing the probabilistic fusion method;
- AMAD-D: the algorithm combines the results of the alpha rhythm detection algorithm and the MRCP detection algorithm for decision-making, employing the decision fusion method based on weighted D-S theory.

In the offline experiment, the EEG data from the first session of each subject are used for algorithms training, while the data from the remaining three sessions are used for algorithms testing. The method for extracting training data from the EEG data in the transition state and idle state is illustrated in Fig. 4. To simulate online asynchronous detection more accurately during testing, a sliding time window of 2 s is used to process continuous EEG signals in each session. The time window moves in steps of 0.1 s. The asynchronous detection algorithms process and classify the signals intercepted in each time window to transition state or idle state. When the algorithm detects three consecutive time windows as transition states, it infers that the subject intended to transition from the idle state to the control state.

その後、アルゴリズムの出力を4秒間停止させ、被験者がMIタスクを実行できるようにする。オフライン実験では、非同期検出アルゴリズムの性能を評価するために3つの指標を使用する：TPR、FPR、オンセット検出時間(ODT)である。

- TPR: 正しい検出(TP)の比率を指す。正しい検出とは、被験者がアイドル状態からコントロール状態への切り替え意図を正しく識別することを意味する。移行意図の総数が決定される場合、この指標は主に見逃し検出数に影響される；
- FPR: 誤検出(FP)の比率を指す。誤検出とは、被験者がアイドル状態から制御状態に切り替える意図を持たないが、アルゴリズムによって誤って遷移意図として識別されることを意味する；
- ODT: アイドル状態から制御状態への切り替え意図をアルゴリズムが検出するのに必要な時間を指す。

TPRとFPRは、それぞれ被験者の移行意図の正しい検出数(TP)と誤った検出数(FP)に基づいて計算される。各被験者は、各セッションにおいて、アイドル状態からコントロール状態への遷移意図を合計30個生成する。制御状態の開始時刻をピープ音で示し、開始時刻の3秒前から1秒後までの時間間隔を定義する。この時間範囲内で被験者の遷移意図を検出することは正しい検出とみなされ、時間範囲外での遷移意図を検出することは正しくない検出とみなされる。TPRはパーセンテージで表し、FPRはfalse positives per minute(FPs/min)で表した。ODTとは、図4に示すように、アルゴリズムが制御状態の開始点を検出するのに必要な時間のことで、被験者が動きを想像し始める瞬間でもある。ODTは、アルゴリズムが運動イメージの開始点を検出する精度を反映しており、正しく検出された場合にのみ意味を持つことに注意すべきである。

3.3. オンライン実験

提案するAMADDS法のオンライン性能をさらに評価するために、実験システムを用いて3人の被験者でオンライン実験を行った。この実験では、開閉動作に助けられた非同期MIパラダイムも利用し、手と足の動きを想像するタスクを行う。実験中、被験者はアイドル状態からコントロール状態へ移行するタイミングを自律的に決定する。しかし、コントロール状態に入る前に、目を閉じてからMIタスクの準備をし、目を閉じている間、簡単に目を閉じることが必要である。ピープ音をシステムから聴いた後、被験者は直ちに目を開け、MI課題を行うよう指示される。各被験者は、自分のペースで60のMIタスクを完了するタスクを課される。実験プロセス全体をビデオに記録し、各被験者が目を閉じた回数をカウントすることで、非同期検出アルゴリズムの性能を評価することができる。

オンライン実験では、システムの非同期検出スレッドは、0.1秒の移動ステップで、2秒のスライディング時間ウィンドウを使用してリアルタイムの脳波信号を処理する。AMAD-DSアルゴリズムは、毎回時間窓を処理し、傍受された信号の状態(遷移またはアイドル)を決定するために適用される。連続する3つの時間窓が遷移状態を示す場合、システムは被験者に短いピープ音を信号化し、非同期検出スレッドを一時停止して、被験者がMIタスクを実行できるようにする。4秒間の休止の後、スレッドはアルゴリズムの実行を再開し、被験者の次の制御状態への参加意図を特定した。

オフライン実験と同様に、オンライン実験では、TPR、FPR、近眼検出時間(CDT)の3つの指標を用いて、AMAD-DSアルゴリズムの性能を評価する。被験者が目を閉じてから5秒以内にアルゴリズムが意図を認識した場合、正しい検出が記録される。閉眼後5秒以上意図を認識しなかった場合、検出漏れが見られ、被験者に開眼を促し、次の課題に進む。




図5. オフライン実験におけるアルゴリズムのTPRの比較。




図6. オフライン実験におけるアルゴリズムのFPRの比較。




図7. オフライン実験におけるアルゴリズムのODTの比較。

被験者が積極的に目を閉じることなく、アルゴリズムが意図を認識した場合に、エラー検出が発生する。オフライン実験とは異なり、オンラインセットアップでは運動イメージの開始をマークできないため、ODTは利用できない。その代わりに、被験者が目を閉じてからアルゴリズムが意図を検出するまでの時間を表すCDTが提供される。

4. 結果と考察

4.1. オフライン実験の結果

AMAD-DSとベンチマークアルゴリズムのオフライン実験の結果を表1に示すが、6人の被験者の脳波データ全体の平均性能指標を示している。図5、図6、図7は、それぞれ異なるアルゴリズム間のTPR、FPR、ODT指標の視覚的比較である。

MAD*アルゴリズムとMADアルゴリズムは、提案されたMRCP検出アルゴリズムに基づいて決定されるが、空間フィルタ構築に使用される方法のみが異なる。

Subsequently, the output of the algorithm is suspended for 4 s to allow the subject to perform the MI task.

The offline experiment uses three indicators to evaluate the performance of the asynchronous detection algorithms: TPR, FPR, and onset detection time (ODT).

- TPR: refers to the ratio of correct detections (TPs). Correct detection means that the subject's intention to switch from idle state to control state is correctly identified. When the total number of transition intentions is determined, this indicator is mainly affected by the number of missed detections;
- FPR: refers to the ratio of false detections (FPs). False detection means that the subject has no intention to switch from idle state to control state, but is mistakenly identified as a transition intention by the algorithm;
- ODT: refers to the time required for the algorithm to detect the subject's intention to switch from idle state to control state.

TPR and FPR are calculated based on the number of correct detections (TPs) and false detections (FPs) of the subject's transition intentions, respectively. Each subject generates a total of 30 transition intentions from the idle state to the control state in each session. The starting time of the control state is indicated by a beep, and this study defines the time interval from 3 s before to 1 s after the starting time. Detecting the subject's transition intention within this time range is considered a correct detection, while detecting the transition intention outside the time range is considered an incorrect detection. TPR is expressed as a percentage, while FPR is expressed as false positives per minute (FPs/min). ODT refers to the time required by the algorithm to detect the starting point of the control state, which is also the moment when the subject starts to imagine movement, as shown in Fig. 4. It should be noted that ODT reflects the accuracy of the algorithm's detection of the start moment of motor imagery and is only meaningful if detected correctly.

3.3. Online experiment

To further assess the online performance of the proposed AMAD-DS method, the online experiment is conducted with three subjects using the experimental system. This experiment also utilizes the asynchronous MI paradigm aided by eye opening and closing movements, with tasks involving imagining hand and foot movements. During the experiment, subjects autonomously decide when to transition from the idle state to the control state. However, they are required to briefly close their eyes before entering the control state and prepare for the MI task while their eyes are closed. Upon hearing a beep from the system, subjects are instructed to immediately open their eyes and perform the MI task. Each subject is tasked with completing 60 MI tasks at their own pace. The entire experimental process is recorded on video to count the times each subject closed their eyes, allowing for the evaluation of the asynchronous detection algorithm's performance.

During the online experiment, the system's asynchronous detection thread processes real-time EEG signals using a sliding time window of 2 s, with a moving step of 0.1 s. The AMAD-DS algorithm is applied to process the time window each time, determining the intercepted signal's state (transition or idle). When three consecutive time windows indicate a transition state, the system signals the subject with a short beep and pause the asynchronous detection thread to allow the subject to perform the MI task. After a 4-s pause, the thread resumed running the algorithm to identify the subject's next intention to enter the control state.

Similar to the offline experiment, the online experiment uses the three indicators of TPR, FPR, and close-eye detection time (CDT) to evaluate the AMAD-DS algorithm's performance. A correct detection is recorded if the algorithm recognizes the intention within 5 s after the subject closes their eyes. Failure to recognize the intention for more than 5 s after eye closure indicates a missed detection, prompting the




Fig. 5. Comparison of TPR for algorithms in offline experiments.




Fig. 6. Comparison of FPR for algorithms in offline experiments.




Fig. 7. Comparison of ODT for algorithms in offline experiments.

subject to open their eyes and proceed to the next task. An error detection occurs if the algorithm recognizes the intention without the subject actively closing their eyes. Unlike the offline experiment, the online setup cannot mark the onset of motor imagery, so ODT is unavailable. Instead, CDT is provided, representing the time from when the subject closes their eyes to when the algorithm detects the intention.

4. Results and discussion

4.1. Results of offline experiment

The results of the offline experiments for AMAD-DS and benchmark algorithms are presented in Table 1, showing the average performance indicators across the EEG data of 6 subjects. Figs. 5, 6 and 7 provide visual comparisons of the TPR, FPR, and ODT indicators among the different algorithms, respectively.

Both the MAD* and MAD algorithms base their decisions on the proposed MRCP detection algorithm, differing only in the method used for spatial filter construction. MAD* utilizes the DCPM method, while

Table 1

AMAD-DSとベンチマークアルゴリズムのオフライン実験結果。

Algorithm	TPs (times)	TPR (%)	FPs (times)	FPR (FPs/min)	ODT (s)
AAD	83.5 ± 4.5	92.8 ± 5.0	5.8 ± 2.3	0.32 ± 0.13	-1.02 ± 0.24
MAD*	68.2 ± 4.9	75.8 ± 5.4	14.2 ± 5.2	0.79 ± 0.29	0.22 ± 0.31
MAD	73.0 ± 4.5	81.1 ± 5.0	11.3 ± 4.9	0.63 ± 0.27	-0.13 ± 0.28
AMAD-D	71.2 ± 4.2	79.1 ± 4.7	1.5 ± 1.1	0.08 ± 0.06	-0.09 ± 0.30
AMAD-P	80.9 ± 4.7	89.9 ± 5.2	3.6 ± 2.2	0.20 ± 0.12	-0.35 ± 0.26
AMAD-DS	84.3 ± 3.9	93.7 ± 4.3	2.3 ± 2.0	0.13 ± 0.11	-0.24 ± 0.22

Table 2

オンライン実験の結果

Subject	Duration (min)	TPs (times)	TPR (%)	FPs (times)	FPR (FPs/min)	CDT (s)
1	13.8	60/66	90.9	4	0.29	1.77
2	16.3	60/63	95.2	1	0.06	1.92
3	15.7	60/68	88.2	2	0.13	1.89
Average	15.3	60/65.7	91.3	3.0	0.16	1.86

MAD*はDCPM法、MADはTRCA法である。MAD*とMADの実験結果を比較すると、後者が前者を上回っていることがわかる。MADのTPR(81.1%)はMAD*のTPR(75.8%)より高く、MADのFPR(0.63FPs/min)はMAD*のFPR(0.79FPs/min)より低い。このことは、TRCA法がDCPM法と比較して、多チャンネル脳波信号におけるMRCP特徴のより良い統合を可能にする優れた空間フィルタリング効果を提供することを示している。さらに、MAD*とMADの両アルゴリズムとも0秒付近のODTを示し、アルゴリズムの検出時間が被験者の運動イメージの開始と密接に一致していることが示唆された。これらの結果は、MRCPの特徴とMI課題との間の時間-位相関係と一致し、被験者の運動イメージの開始を示すMRCPの役割を裏付けるものである。

アルゴリズムAADとMADはそれぞれ、提案するアルファリズム検出アルゴリズムとMRCP検出アルゴリズムに基づいて決定を行う。AADとMADの実験結果を比較すると、AADのTPR(92.8%)はMADのTPR(81.1%)より有意に高く、AADのFPR(0.32FPs/min)はMADのFPR(0.63FPs/min)より有意に低いことがわかる。これらの結果は、AADが検出精度の点でMADを上回ることが示している。これは主に、閉眼によって誘発されるアルファリズム特徴がMRCP特徴よりも顕著で安定しているためである。さらに、AADのODTは約-1秒であり、運動イメージの開始1秒前から検出が起きていることが示唆される。しかし、このことは、AADは主に閉眼によるアルファリズムの変化を識別するため、運動イメージ開始の正確な瞬間を正確に検出できない可能性があり、その結果、MADと比較してオンセット検出精度に潜在的な不利をもたらす可能性があることも示唆している。

AMAD-D、AMAD-P、AMAD-DSのアルゴリズムは、それぞれ異なる決定融合手法を利用し、アルファリズムとMRCP検出アルゴリズムの結果を統合して決定を行う。実験の結果、AMAD-Dアルゴリズムは79.1%のTPRと0.08FPs/minのFPRを達成し、AMAD-Pアルゴリズムは89.9%のTPRと0.20FPs/minのFPRを達成し、AMAD-DSアルゴリズムは93.7%のTPRと0.13FPs/minのFPRを達成した。AMAD-Dは被験者の遷移意図を検出するための最も厳密な基準を持ち、その結果、FPが最も少なく、FPRが最も優れている。しかし、この厳密さはTPRを損なう。TPRとFPRを比較すると、AMAD-PとAMAD-DSはAMAD-Dを上回り、TPRが有意に高く、FPRが比較的低い。その中で、AMAD-DSはAMAD-Pよりも高いTPRと低いFPRを達成し、3つのアルゴリズムの中で最も性能の良いアルゴリズムとなっている。さらに、ODTの観点からは、3つのアルゴリズムの検出モーメントは、運動イメージの開始に比較的近いが、両者の間にはわずかな違いがある。

AAD、MAD、AMAD-DSの3つのアルゴリズムの実験結果のうち、AADアルゴリズムはTPR 92.8%、FPR 0.32 FPs/min、ODT -1.02 sを達成した。MADアルゴリズムは、TPR81.1%、FPR0.63FPs/min、ODT-0.13sを達成した。

AMAD-DSアルゴリズムは、TPR 93.7%、FPR 0.13 FPs/min、ODT -0.24 sを達成した。これらの結果から、AMADDSアルゴリズムはTPRとFPRにおいてAADアルゴリズムをわずかに上回り、そのODTはMADアルゴリズムに近いことがわかる。これは、AMAD-DSアルゴリズムがAADアルゴリズムとMADアルゴリズムの長所を効果的に組み合わせ、AADアルゴリズムのオンセット検出の限界とMADアルゴリズムの検出精度の低さに対処し、それによってTPR、FPR、ODTの同時最適化と改善を達成していることを示している。

4.2. オンライン実験の結果

表2はオンライン実験の結果であり、3人の被験者が60の運動イメージ課題を完了するのにそれぞれ13.8分、16.3分、15.7分かかる。実験結果から、以下の結論が得られた：まず、3人の被験者の平均TPRは91.5%、FPRは0.16FPs/minであり、約6分ごとに1回の誤検出に相当する。これは、AMAD-DSアルゴリズムがオンライン・モードで被験者の遷移意図を正確に識別できることを示している。次に、3人の被験者の平均CDTは1.86秒であり、被験者が目を閉じた瞬間から、AMADDSアルゴリズムは認識処理を完了するのに平均1.86秒かかることを意味する。オンライン実験から得られた様々な性能指標に基づき、提案する非同期検出アルゴリズムがオンラインアプリケーションに適していることが実証された。

5. おわりに

BCI、特にMI-EEGシステムの進歩は、人間とコンピュータの間のギャップを大きく埋めている。非同期BCIは、柔軟性を高め、ユーザーの期待に密接に合致し、実用化においてますます重要になってきている。しかし、既存のMI-EEG非同期検出法の精度とレイテンシは依然として最適ではない。本論文では、重み付きDempster-Shafer理論を用いて、アルファリズムとMRCP特徴を組み合わせたハイブリッド非同期検出法AMAD-DSを紹介する。この方法は、後頭部と感覚運動野の両方からの脳波信号を処理し、マルチドメイン共同分析を利用して特徴を抽出・評価する。オフラインの実験結果は、AMAD-DSがMRCPまたはアルファリズム特徴のみに依存する手法を凌駕し、より高い検出精度と待ち時間の短縮を達成することを示している。具体的には、TPRを平均12.6%向上させ、FPRを平均0.5FPs/min低下させるとともに、運動イメージのオンセット検出精度を500ms以内に向上させる。オンライン実験では、AMAD-DSは91.1%のTPRと0.16FPs/minのFPRを達成し、その有効性と実用的なBCIアプリケーションへの可能性を検証した。今後の課題として、アルゴリズムの性能を総合的に評価するために、テストプロセスをさらに改善する必要がある、アルゴリズムの実用性を向上させるために、被験者横断的なキャリブレーションと長期的な安定利用の観点からアルゴリズム設計を最適化する必要がある。

Table 1
Results of offline experiment for AMAD-DS and benchmark algorithms.

Algorithm	TPs (times)	TPR (%)	FPs (times)	FPR (FPs/min)	ODT (s)
AAD	83.5 ± 4.5	92.8 ± 5.0	5.8 ± 2.3	0.32 ± 0.13	−1.02 ± 0.24
MAD*	68.2 ± 4.9	75.8 ± 5.4	14.2 ± 5.2	0.79 ± 0.29	0.22 ± 0.31
MAD	73.0 ± 4.5	81.1 ± 5.0	11.3 ± 4.9	0.63 ± 0.27	−0.13 ± 0.28
AMAD-D	71.2 ± 4.2	79.1 ± 4.7	1.5 ± 1.1	0.08 ± 0.06	−0.09 ± 0.30
AMAD-P	80.9 ± 4.7	89.9 ± 5.2	3.6 ± 2.2	0.20 ± 0.12	−0.35 ± 0.26
AMAD-DS	84.3 ± 3.9	93.7 ± 4.3	2.3 ± 2.0	0.13 ± 0.11	−0.24 ± 0.22

Table 2
Results of online experiments.

Subject	Duration (min)	TPs (times)	TPR (%)	FPs (times)	FPR (FPs/min)	CDT (s)
1	13.8	60/66	90.9	4	0.29	1.77
2	16.3	60/63	95.2	1	0.06	1.92
3	15.7	60/68	88.2	2	0.13	1.89
Average	15.3	60/65.7	91.3	3.0	0.16	1.86

MAD uses the TRCA method. A comparison of the experimental results between MAD* and MAD reveals that the latter outperforms the former. The TPR of MAD (81.1%) is higher than that of MAD* (75.8%), while the FPR of MAD (0.63 FPs/min) is lower than that of MAD* (0.79 FPs/min). This indicates that the TRCA method offers superior spatial filtering effects, enabling better integration of MRCP features in multi-channel EEG signals compared to the DCPM method. Additionally, both MAD* and MAD algorithms exhibit an ODT near 0 s, suggesting that the algorithm's detection time closely aligns with the onset of the subject's motor imagery. These results align with the time-phase relationship between MRCP features and MI tasks, confirming the MRCP's role in indicating the onset of subjects' motor imagery.

The algorithms AAD and MAD each make decisions based on the proposed alpha rhythm detection algorithm and MRCP detection algorithm, respectively. Upon comparing the experimental results of AAD and MAD, it is observed that the TPR of AAD (92.8%) is significantly higher than that of MAD (81.1%), while the FPR of AAD (0.32 FPs/min) is notably lower than that of MAD (0.63 FPs/min). These findings indicate that AAD outperforms MAD in terms of detection accuracy, primarily because the alpha rhythm features induced by eye closure are more pronounced and stable than the MRCP features. Furthermore, the ODT of AAD is approximately −1 s, suggesting that the detection occurs around 1 s before the onset of motor imagery. However, this also implies that AAD may not accurately detect the exact moment of motor imagery initiation, as it primarily identifies changes in alpha rhythm due to eye closure, resulting in a potential disadvantage in onset detection accuracy compared to MAD.

The algorithms AMAD-D, AMAD-P, and AMAD-DS all integrate the results of alpha rhythm and MRCP detection algorithms to make decisions, utilizing different decision fusion methods. Experimental results indicate that the AMAD-D algorithm achieves a TPR of 79.1% and a FPR of 0.08 FPs/min, the AMAD-P algorithm achieves a TPR of 89.9% and an FPR of 0.20 FPs/min, while the AMAD-DS algorithm achieves a TPR of 93.7% and an FPR of 0.13 FPs/min. AMAD-D has the strictest criteria for detecting the subject's transition intention, resulting in the fewest FPs and the best FPR. However, this strictness compromises its TPR. Comparing the TPR and FPR, both AMAD-P and AMAD-DS outperform AMAD-D, with significantly higher TPR and relatively low FPR. Among them, AMAD-DS achieves a higher TPR and lower FPR than AMAD-P, making it the best-performing algorithm among the three. Additionally, in terms of ODT, the detection moments of the three algorithms are relatively close to the onset of motor imagery, with minor differences among them.

Among the experimental results for the three algorithms AAD, MAD, and AMAD-DS, the AAD algorithm achieves a TPR of 92.8%, an FPR of 0.32 FPs/min, and an ODT of −1.02 s. The MAD algorithm achieves a TPR of 81.1%, an FPR of 0.63 FPs/min, and an ODT of −0.13 s. The AMAD-DS algorithm achieves a TPR of 93.7%, an FPR of 0.13 FPs/min,

and an ODT of −0.24 s. From these results, it is evident that the AMAD-DS algorithm slightly outperforms the AAD algorithm in TPR and FPR, while its ODT is closer to that of the MAD algorithm. This indicates that the AMAD-DS algorithm effectively combines the strengths of the AAD and MAD algorithms, addressing the AAD algorithm's limitation in onset detection and the MAD algorithm's lower detection accuracy, thereby achieving simultaneous optimization and improvement in TPR, FPR, and ODT.

4.2. Results of online experiment

Table 2 presents the results of the online experiment, where three subjects take 13.8 min, 16.3 min, and 15.7 min to complete 60 motor imagery tasks, respectively. The experimental results yield the following conclusions: First, the average TPR for the three subjects is 91.5%, and the FPR is 0.16 FPs/min, equivalent to one false detection approximately every 6 min. This indicates that the AMAD-DS algorithm can accurately identify the subject's transition intention in online mode. Second, the average CDT for the three subjects is 1.86 s, meaning that, starting from the moment the subjects close their eyes, the AMAD-DS algorithm takes an average of 1.86 s to complete the recognition process. Based on various performance indicators obtained from the online experiment, the proposed asynchronous detection algorithm is demonstrated to be suitable for online applications.

5. Conclusion

The advancement of BCI, particularly MI-EEG systems, has significantly bridged the gap between humans and computers. Asynchronous BCIs, offering enhanced flexibility, align more closely with user expectations and are becoming increasingly vital in practical applications. However, the accuracy and latency of existing MI-EEG asynchronous detection methods remain suboptimal. This paper introduces a hybrid asynchronous detection method, AMAD-DS, which combines alpha rhythm and MRCP features using weighted Dempster–Shafer theory. This method processes EEG signals from both the occipital and sensorimotor areas, utilizing multi-domain joint analysis to extract and assess features. Offline experimental results demonstrate that AMAD-DS outperforms methods relying solely on MRCP or alpha rhythm features, achieving higher detection accuracy and reduced latency. Specifically, it enhances the TPR by an average of 12.6% and decreases the FPR by an average of 0.5 FPs/min, while also improving the onset detection accuracy of motor imagery to within 500 ms. In online experiments, AMAD-DS achieves a TPR of 91.1% and a FPR of 0.16 FPs/min, validating its effectiveness and potential for practical BCI applications. In future work, the testing process needs to be further improved to comprehensively evaluate the algorithm performance, and the algorithm design needs to be optimized from the perspectives of cross-subject calibration and long-term stable use to improve the practicality of the algorithm.

CRedit オーサーシップ貢献声明

Xiaolin Liu: 執筆 - レビューと編集, 執筆 - 原案, 可視化, 検証, ソフトウェア, 方法論, 調査, データキュレーション, 概念化. Ying Sun: データキュレーション, 形式分析, 調査, 方法論, 検証, 可視化, 執筆 - レビューと編集. Shuai Wang: 執筆-校閲・編集, 方法論, 形式分析, 概念化. Jun Yan: 執筆-校閲・編集, プロジェクト管理, 調査, 資金獲得, 概念化. Ziyu Jiang: 執筆 - レビューと編集, 可視化, 検証. Dezhi Zheng: 監修, プロジェクト管理, 資金獲得, 概念化.

競合する利害関係の宣言

我々は、我々の研究に不適切な影響を与える可能性のある他の人々や組織との金銭的および個人的な関係がないことを宣言する。また、原稿で提示された立場や査読に影響を与えると解釈され得る、いかなる製品、サービス、または企業においても、いかなる性質または種類の職業的またはその他の個人的利益もないことを宣言する。

データの利用可能性

データはリクエストに応じて提供する。

参考文献

- [1] R. 脳卒中リハビリテーションのためのBCI:運動とその先, J. Neural Eng. 17 (4) (2020) 041001.
- [2] R. SAVEP-BCI電気車椅子のハイブリッド刺激装置による埋め込み型軽量SSVEP-BCI電気車椅子, Digit. 信号処理 116 (2021) 103101.
- [3] C. 楊, 梁, 張, X. Geng, サブクラスタリング戦略に基づく冗長性除去モデルによる構造的健康モニタリングのためのセンサ配置アルゴリズム, Mech. Syst. 信号処理. 124 (2019) 369-387.
- [4] C. 楊, 歐陽, マルチソース不確実性を考慮した時間依存信頼性最適化に基づくモデル更新のための新しい負荷依存センサー配置法, Mech. Syst. 信号処理. 165 (2022) 108386.
- [5] R. シン, 張, 劉, 張, S. クマール, WaveFlex バイオセンサー: MXene固定化W字型ファイバーベースLSPPRセンサーによる高選択的テラミン検出, Opt. レーザー技術 171 (2024) 110357.
- [6] S. Kumar, A. Iadicicco, S. Kim, D. Tosi, C. Marques, 特徴問題の紹介: バイオメディカル応用のための光バイオセンサーの進歩, Biomed. Express 15 (5) (2024) 3183-3190.
- [7] C. 楊, Z. ファン, W. ルー, H. ガオ, 信頼性制約のある周期的衛星のための不確実な反復最適姿勢制御法, IEEE Trans. エアロスペース, 電子, システム (2024).
- [8] H.C. Gomes, X. Liu, A. Fernandes, C. Moreirinha, R. Singh, S. Kumar, F. Costa, N. Santos, C. Marques, レーザー誘起グラフェンベースファブリーペロー空洞ラベルフリー免疫センサーによるコルチゾールの定量化, Sens. アクチュエータトリップ 7 (2024) 100186.
- [9] C. Yang, マルチソース不確実性を伴う力再構成のための区間戦略に基づく正則化アプローチ, Comput. Methods Appl. 419 (2024) 116679.
- [10] C. 楊, Z. ファン, Y. シャ, 不確実な制御系のための凸モデルベースの低次モデル, IEEE Trans. システム. 人間サイバネ:システム (2024).
- [11] F. ロッテ, L. ブーグレイン, A. シチョッキ, M. クレック, M. コンゲド, A. ラコトマモンジ, F. イェーガー, EEGベースのブレイン・コンピュータ・インターフェースの分類アルゴリズムのレビュー: A 10 year update, J. Neural Eng. 15 (3) (2018) 031005.
- [12] R. 高品質SSVEP-BCI信号取得のためのウェアラブル低消費電力協調センシングシステム, IEEE Internet Things J. 9 (10) (2021) 7273-7285.
- [13] Y. (1)SSVEP-BCIにおける時間重み付け正準相関分析に基づく被験者間融合, Measurement 199 (2022) 111524.
- [14] A. アルツハイマー病の脳波バイオマーカーの系統的レビューと方法論的解析, Measurement (2023) 113274.
- [15] H. Wang, Y. Zhang, et al., ナイーブイズに基づく学習過程を用いた運動イメージ脳波信号の検出, Measurement 86 (2016) 148-158.
- [16] S. (1)運動イメージ分類のための共通空間パターンとフィッシャー判別分析によるデシメーションフィルタ, in: 2016 International Joint Conference on Neural Networks, IJCNN, IEEE, 2016, pp. 2090-2095.
- [17] M.Z. Baig, N. Aslam, H.P. Shum, L. Zhang, 運動イメージ脳波における最適特徴部分集合選択のためのツールとしての微分進化アルゴリズム, Expert Syst. 申請90 (2017) 184-195.
- [18] V.P. Oikonomou, K. Georgiadis, G. Liaros, S. Nikolopoulos, I. Kompatsiaris, 運動イメージ脳波データを用いた脳波信号処理技術の比較研究, in: 2017 IEEE 30th International Symposium on Computer-Based Medical Systems, CBMS, IEEE, 2017, pp. 781-786.
- [19] D. 程, 劉, 張, ディープニューラルネットワークを用いた脳卒中患者の運動イメージ脳波パターンの探索, in: 2018 IEEE International Conference on Acoustics, Speech and Signal Processing, ICASSP, IEEE, 2018, pp. 2561-2565.
- [20] S. 丁, 張, 李, 孫, 運動イメージ時の脳制御スイッチの研究, in: 2018 3rd International Conference on Advanced Robotics and Mechatronics, ICARM, IEEE, 2018, pp. 152-157.
- [21] S. ロドボンブン, T. ジャニヤリキット, C.A. Ratanamahatana, et al., 移動意図検出のための非同期BCIの影響因子, Comput. 数学. 方法医学. 2020 (2020) 1-12.
- [22] G. プルツシェラー, T. ソリス・エスカランテ, R. オルトナー, P. リノルトナー, G. R. Müller-Putz, SSVEPベースの装置の自己ベース操作とイメージベースの「ブレインスイッチ」の有無: ハイブリッドBCIに向けたフィジビリティスタディ, IEEE Trans. ニューラル・システム. リハビリテーション. 18 (4) (2010) 409-414.
- [23] G.R. Müller-Putz, V. Kaiser, T. Solis-Escalante, G. Pfurtscheller, 1チャンネル脳波における足部運動イメージの検出に基づく高速セットアップ非同期脳スイッチ, Med. を計算した. 48 (2010) 229-233.
- [24] K. 銭, P. ニコロフ, D. ホアン, D.-Y. Fei, X. Chen, O. Bai, 運動イメージに基づくオンライン対話型脳制御スイッチ:パラダイム開発と予備テスト, Clin. 神経生理学 121 (8) (2010) 1304-1313.
- [25] C. マルクス・チン, A. マルクス, M.R. Popovic, et al., 重度片麻痺を伴う慢性脳卒中における上肢機能回復のための脳波トリガー機能的電気刺激療法, Case Rep. 神経. 医学. 2016 (2016) 1-11.
- [26] H. 柴崎秀樹, M. Hallett, 阻害要因とは?臨床 117 (11) (2006) 2341-2356.
- [27] ニアジ, 江, ティベルヒエン, J.F. Nielsen, K. Dremstrup, D. Farina, 単一試行の運動関連皮質電位からの運動意図の検出, J. Neural Eng. 8 (6) (2011) 066009.
- [28] I.K. Niazi, N. Mrachacz-Kersting, N. Jiang, K. Dremstrup, D. Farina, 運動意図の自己ベース検出による末梢電気刺激は運動誘発電位を増強する, IEEE Trans. ニューラル・システム. リハビリテーション. 20 (4) (2012) 595-604.
- [29] ニアジ, 江, ヨクムセン, J.F. Nielsen, K. Dremstrup, D. Farina, 被験者非依存型トレーニングに基づく運動関連皮質電位の検出, Med. 生物学. Comput. 51 (2013) 507-512.
- [30] R. 徐, 姜, 林, N. Mrachacz-Kersting, K. Dremstrup, D. Farina, 閉ループブレインコンピュータインターフェースアプリケーションのためのEEGからの運動意図の低遅延検出の強化, IEEE Trans. バイオメディカル 61 (2) (2013) 288-296.
- [31] K.K. アン, Z.Y. チン, C. ワン, C. グアン, H. チャン, BCI競技IVデータセット2aおよび2bにおけるフィルターバンク共通空間パターンアルゴリズム, フロント. 神経科学 6 (2012) 39.
- [32] X. 劉, 孫, 鄭, R. Na, Hilbert-Huang 変換に基づく運動イメージ脳波分類のための被験者固有の時間-周波数-空間パターン最適化, Measurement 223 (2023) 113673.
- [33] 黄直英, 沈志, S.R. ロング, M.C. 呉, H.H. 石, Q. 鄭, N.-C. イェン, C.C. Tung, H. H. Liu, 非線形・非定常時系列解析のための経験的モード分解とヒルベルトスペクトル, Proc. R. Soc. Lond. 数学. Phys. Eng. 科学 454 (1971) (1998) 903-995.
- [34] N.E. Huang, Z. Wu, Hilbert-Huang 変換に関する総説: 方法と地球物理学的研究への応用, Rev. 地質学 46 (2) (2008) 1-23.
- [35] M. 中西正樹, 王洋一, 陳曉, Y.-T. Wang, X. Gao, T.-P. Jung, タスク関連成分分析を用いた高速脳内スペラーのSSVEP検出の強化, IEEE Trans. バイオメッド. 65 (1) (2017) 104-112.
- [36] K. 王, 徐, 王, 張, 陳, 明, ブレイン・コンピュータ・インターフェースのための運動前脳波パターンの強化デコーディング, J. Neural Eng. 17 (1) (2020) 016033.
- [37] D. Weenink, Canonical correlation analysis, in: アムステルダム大学音声科学研究講演文集, Vol. 25, アムステルダム大学, 2003, pp. 81-99.
- [38] Y.-T. 劉, N.R. バル, A.R. マラテ, C.-T. Lin, マルチモーダル情報統合のための重み付きファジィDempster-Shaferフレームワーク, IEEE Trans. ファジィシステム 26 (1) (2017) 338-352.

CRediT authorship contribution statement

Xiaolin Liu: Writing – review & editing, Writing – original draft, Visualization, Validation, Software, Methodology, Investigation, Data curation, Conceptualization. **Ying Sun:** Data curation, Formal analysis, Investigation, Methodology, Validation, Visualization, Writing – review & editing. **Shuai Wang:** Writing – review & editing, Methodology, Formal analysis, Conceptualization. **Jun Yan:** Writing – review & editing, Project administration, Investigation, Funding acquisition, Conceptualization. **Ziyu Jiang:** Writing – review & editing, Visualization, Validation. **Dezhi Zheng:** Supervision, Project administration, Funding acquisition, Conceptualization.

Declaration of competing interest

We declare that we have no financial and personal relationships with other people or organizations that can inappropriately influence our work, there is no professional or other personal interest of any nature or kind in any product, service and/or company that could be construed as influencing the position presented in, or the review of, the manuscript.

Data availability

Data will be made available on request.

References

- [1] R. Mane, T. Chouhan, C. Guan, BCI for stroke rehabilitation: motor and beyond, *J. Neural Eng.* 17 (4) (2020) 041001.
- [2] R. Na, C. Hu, Y. Sun, S. Wang, S. Zhang, M. Han, W. Yin, J. Zhang, X. Chen, D. Zheng, An embedded lightweight SSVEP-BCI electric wheelchair with hybrid stimulator, *Digit. Signal Process.* 116 (2021) 103101.
- [3] C. Yang, K. Liang, X. Zhang, X. Geng, Sensor placement algorithm for structural health monitoring with redundancy elimination model based on sub-clustering strategy, *Mech. Syst. Signal Process.* 124 (2019) 369–387.
- [4] C. Yang, H. Ouyang, A novel load-dependent sensor placement method for model updating based on time-dependent reliability optimization considering multi-source uncertainties, *Mech. Syst. Signal Process.* 165 (2022) 108386.
- [5] R. Singh, W. Zhang, X. Liu, B. Zhang, S. Kumar, WaveFlex biosensor: MXene-immobilized W-shaped fiber-based LSPR sensor for highly selective tyramine detection, *Opt. Laser Technol.* 171 (2024) 110357.
- [6] S. Kumar, A. Iadicco, S. Kim, D. Tosi, C. Marques, Introduction to the feature issue: Advances in optical biosensors for biomedical applications, *Biomed. Opt. Express* 15 (5) (2024) 3183–3190.
- [7] C. Yang, Z. Fan, W. Lu, H. Gao, Uncertain iterative optimal attitude control method for periodic satellite with reliability constraint, *IEEE Trans. Aerosp. Electron. Syst.* (2024).
- [8] H.C. Gomes, X. Liu, A. Fernandes, C. Moreirinha, R. Singh, S. Kumar, F. Costa, N. Santos, C. Marques, Laser-induced graphene-based Fabry-Pérot cavity label-free immunosensors for the quantification of cortisol, *Sens. Actuators Rep.* 7 (2024) 100186.
- [9] C. Yang, Interval strategy-based regularization approach for force reconstruction with multi-source uncertainties, *Comput. Methods Appl. Mech. Engrg.* 419 (2024) 116679.
- [10] C. Yang, Z. Fan, Y. Xia, Convex model-based reduced-order model for uncertain control systems, *IEEE Trans. Syst. Man Cybern.: Syst.* (2024).
- [11] F. Lotte, L. Bougrain, A. Cichocki, M. Clerc, M. Congedo, A. Rakotomamonjy, F. Yger, A review of classification algorithms for EEG-based brain-computer interfaces: A 10 year update, *J. Neural Eng.* 15 (3) (2018) 031005.
- [12] R. Na, D. Zheng, Y. Sun, M. Han, S. Wang, S. Zhang, Q. Hui, X. Chen, J. Zhang, C. Hu, A wearable low-power collaborative sensing system for high-quality SSVEP-BCI signal acquisition, *IEEE Internet Things J.* 9 (10) (2021) 7273–7285.
- [13] Y. Sun, W. Ding, X. Liu, D. Zheng, X. Chen, Q. Hui, R. Na, S. Wang, S. Fan, Cross-subject fusion based on time-weighting canonical correlation analysis in SSVEP-BCIs, *Measurement* 199 (2022) 111524.
- [14] A. Modir, S. Shamekhi, P. Ghaderyan, A systematic review and methodological analysis of EEG-based biomarkers of Alzheimer's disease, *Measurement* (2023) 113274.
- [15] H. Wang, Y. Zhang, et al., Detection of motor imagery EEG signals employing Naive Bayes based learning process, *Measurement* 86 (2016) 148–158.
- [16] S. Kumar, R. Sharma, A. Sharma, T. Tsunoda, Decimation filter with common spatial pattern and fishers discriminant analysis for motor imagery classification, in: 2016 International Joint Conference on Neural Networks, IJCNN, IEEE, 2016, pp. 2090–2095.
- [17] M.Z. Baig, N. Aslam, H.P. Shum, L. Zhang, Differential evolution algorithm as a tool for optimal feature subset selection in motor imagery EEG, *Expert Syst. Appl.* 90 (2017) 184–195.
- [18] V.P. Oikonomou, K. Georgiadis, G. Liaros, S. Nikolopoulos, I. Kompatsiaris, A comparison study on EEG signal processing techniques using motor imagery EEG data, in: 2017 IEEE 30th International Symposium on Computer-Based Medical Systems, CBMS, IEEE, 2017, pp. 781–786.
- [19] D. Cheng, Y. Liu, L. Zhang, Exploring motor imagery EEG patterns for stroke patients with deep neural networks, in: 2018 IEEE International Conference on Acoustics, Speech and Signal Processing, ICASSP, IEEE, 2018, pp. 2561–2565.
- [20] S. Ding, H. Zhang, J. Li, C. Li, L. Sun, Study of a brain-controlled switch during motor imagery, in: 2018 3rd International Conference on Advanced Robotics and Mechatronics, ICARM, IEEE, 2018, pp. 152–157.
- [21] S. Rodpongpun, T. Janyalikit, C.A. Ratanamahatana, et al., Influential factors of an asynchronous BCI for movement intention detection, *Comput. Math. Methods Med.* 2020 (2020) 1–12.
- [22] G. Pfurtscheller, T. Solis-Escalante, R. Ortner, P. Linortner, G.R. Müller-Putz, Self-paced operation of an SSVEP-Based orthosis with and without an imagery-based "brain switch": A feasibility study towards a hybrid BCI, *IEEE Trans. Neural Syst. Rehabil. Eng.* 18 (4) (2010) 409–414.
- [23] G.R. Müller-Putz, V. Kaiser, T. Solis-Escalante, G. Pfurtscheller, Fast set-up asynchronous brain-switch based on detection of foot motor imagery in 1-channel EEG, *Med. Biol. Eng. Comput.* 48 (2010) 229–233.
- [24] K. Qian, P. Nikolov, D. Huang, D.-Y. Fei, X. Chen, O. Bai, A motor imagery-based online interactive brain-controlled switch: paradigm development and preliminary test, *Clin. Neurophysiol.* 121 (8) (2010) 1304–1313.
- [25] C. Marquez-Chin, A. Marquis, M.R. Popovic, et al., EEG-triggered functional electrical stimulation therapy for restoring upper limb function in chronic stroke with severe hemiplegia, *Case Rep. Neurol. Med.* 2016 (2016) 1–11.
- [26] H. Shibasaki, M. Hallett, What is the Bereitschaftspotential? *Clin. Neurophysiol.* 117 (11) (2006) 2341–2356.
- [27] I.K. Niazi, N. Jiang, O. Tiberghien, J.F. Nielsen, K. Dremstrup, D. Farina, Detection of movement intention from single-trial movement-related cortical potentials, *J. Neural Eng.* 8 (6) (2011) 066009.
- [28] I.K. Niazi, N. Mrachacz-Kersting, N. Jiang, K. Dremstrup, D. Farina, Peripheral electrical stimulation triggered by self-paced detection of motor intention enhances motor evoked potentials, *IEEE Trans. Neural Syst. Rehabil. Eng.* 20 (4) (2012) 595–604.
- [29] I.K. Niazi, N. Jiang, M. Jochumsen, J.F. Nielsen, K. Dremstrup, D. Farina, Detection of movement-related cortical potentials based on subject-independent training, *Med. Biol. Eng. Comput.* 51 (2013) 507–512.
- [30] R. Xu, N. Jiang, C. Lin, N. Mrachacz-Kersting, K. Dremstrup, D. Farina, Enhanced low-latency detection of motor intention from EEG for closed-loop brain-computer interface applications, *IEEE Trans. Biomed. Eng.* 61 (2) (2013) 288–296.
- [31] K.K. Ang, Z.Y. Chin, C. Wang, C. Guan, H. Zhang, Filter bank common spatial pattern algorithm on BCI competition IV datasets 2a and 2b, *Front. Neurosci.* 6 (2012) 39.
- [32] X. Liu, Y. Sun, D. Zheng, R. Na, Hilbert–Huang Transformation-based subject-specific time–frequency–space pattern optimization for motor imagery electroencephalogram classification, *Measurement* 223 (2023) 113673.
- [33] N.E. Huang, Z. Shen, S.R. Long, M.C. Wu, H.H. Shih, Q. Zheng, N.-C. Yen, C.C. Tung, H.H. Liu, The empirical mode decomposition and the Hilbert spectrum for nonlinear and non-stationary time series analysis, *Proc. R. Soc. Lond. Ser. A Math. Phys. Eng. Sci.* 454 (1971) (1998) 903–995.
- [34] N.E. Huang, Z. Wu, A review on Hilbert–Huang transform: Method and its applications to geophysical studies, *Rev. Geophys.* 46 (2) (2008) 1–23.
- [35] M. Nakanishi, Y. Wang, X. Chen, Y.-T. Wang, X. Gao, T.-P. Jung, Enhancing detection of SSVEPs for a high-speed brain speller using task-related component analysis, *IEEE Trans. Biomed. Eng.* 65 (1) (2017) 104–112.
- [36] K. Wang, M. Xu, Y. Wang, S. Zhang, L. Chen, D. Ming, Enhance decoding of pre-movement EEG patterns for brain–computer interfaces, *J. Neural Eng.* 17 (1) (2020) 016033.
- [37] D. Weenink, Canonical correlation analysis, in: *Proceedings of the Institute of Phonetic Sciences of the University of Amsterdam*, Vol. 25, University of Amsterdam Amsterdam, 2003, pp. 81–99.
- [38] Y.-T. Liu, N.R. Pal, A.R. Marathe, C.-T. Lin, Weighted fuzzy Dempster–Shafer framework for multimodal information integration, *IEEE Trans. Fuzzy Syst.* 26 (1) (2017) 338–352.